

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN-TIN



DỰ BÁO NHU CẦU THUÊ XE ĐẠP
THEO GIỜ SỬ DỤNG MÔ HÌNH
CHUỖI THỜI GIAN NHIỀU CHIỀU

ĐỒ ÁN CHUỖI THỜI GIAN

Chuyên ngành: Toán Tin

Giảng viên hướng dẫn: PGS.TS. Nguyễn Thị Ngọc Anh

Nhóm sinh viên thực hiện: Nguyễn Phan Trung Hiếu - 20227111

Nguyễn Văn Quang - 20227146

Phạm Minh Tuấn - 20227160

Lời cảm ơn

Trước hết, nhóm chúng em xin gửi lời cảm ơn chân thành và sâu sắc tới PGS.TS. Nguyễn Thị Ngọc Anh, giảng viên hướng dẫn học phần Chuỗi thời gian. Trong quá trình học tập và thực hiện đồ án, cô đã tận tình giảng dạy, định hướng và đưa ra những yêu cầu cụ thể giúp nhóm chúng em hiểu rõ hơn về cách tiếp cận một bài toán dự báo chuỗi thời gian trong thực tế.

Nhờ những kiến thức được cô truyền đạt trong học phần, nhóm chúng em đã có cơ sở để lựa chọn đề tài, tìm hiểu các bài báo liên quan, xây dựng quy trình xử lý dữ liệu, thiết kế đặc trưng, huấn luyện mô hình và đánh giá kết quả dự báo. Những góp ý và định hướng của cô là nền tảng quan trọng giúp nhóm hoàn thiện đồ án này.

Nhóm chúng em cũng xin gửi lời cảm ơn tới Khoa Toán - Tin, Đại học Bách khoa Hà Nội đã tạo điều kiện học tập và cung cấp môi trường thuận lợi để chúng em tiếp cận các kiến thức về toán ứng dụng, tin học và mô hình hóa dữ liệu.

Bên cạnh đó, nhóm xin cảm ơn các tác giả của bộ dữ liệu UCI Bike Sharing Dataset và các công trình nghiên cứu về dự báo chuỗi thời gian đã cung cấp nguồn dữ liệu và tài liệu tham khảo hữu ích cho quá trình thực hiện đồ án.

Do thời gian thực hiện và kinh nghiệm nghiên cứu còn hạn chế, đồ án khó tránh khỏi những thiếu sót. Nhóm chúng em rất mong nhận được những nhận xét, góp ý từ cô để có thể tiếp tục hoàn thiện kiến thức và cải thiện hướng nghiên cứu trong tương lai.

Nhóm chúng em xin chân thành cảm ơn!

Tóm tắt nội dung Đề án

Dự báo chuỗi thời gian nhiều chiều là một bài toán quan trọng trong nhiều lĩnh vực thực tế, khi biến mục tiêu cần dự báo không chỉ phụ thuộc vào giá trị quá khứ của chính nó mà còn chịu ảnh hưởng từ nhiều yếu tố bên ngoài. Trong đề án này, nhóm nghiên cứu bài toán dự báo nhu cầu thuê xe đạp theo giờ dựa trên bộ dữ liệu UCI Bike Sharing Dataset. Đây là bài toán có đầu vào là chuỗi thời gian nhiều chiều, bao gồm các biến về thời gian, mùa vụ, thời tiết, nhiệt độ, độ ẩm, tốc độ gió và nhu cầu thuê xe trong quá khứ; đầu ra là biến mục tiêu một chiều biểu thị tổng số xe được thuê trong giờ tiếp theo.

Mục tiêu của đề án là xây dựng một quy trình dự báo hoàn chỉnh, bắt đầu từ phân tích dữ liệu, tiền xử lý, tạo đặc trưng, chia tập dữ liệu theo thứ tự thời gian, huấn luyện mô hình và đánh giá kết quả. Nhóm đã thực hiện kiểm tra dữ liệu thiếu, kiểm tra tần suất lấy mẫu, xử lý outlier, tạo các biến thời gian như giờ, ngày trong tuần, tháng và cuối tuần. Bên cạnh đó, nhóm xây dựng thêm Fourier features để biểu diễn tính chu kỳ, lag features để khai thác thông tin quá khứ và rolling features để mô tả xu hướng ngắn hạn.

Về mặt lý thuyết, nhóm tìm hiểu và tóm tắt ba bài báo liên quan đến dự báo chuỗi thời gian nhiều chiều, bao gồm iTransformer, TimeMixer và xLSTM-Mixer. Các bài báo này cung cấp cơ sở để nhóm nhận thức rõ hơn vai trò của quan hệ giữa các biến, thông tin đa thang đo, tính mùa vụ và phụ thuộc theo thời gian trong bài toán dự báo.

Trong phần thực nghiệm, nhóm xây dựng và so sánh năm mô hình gồm Naive Forecast, Moving Average, Linear Regression, Random Forest và GRU. Các mô hình được đánh giá trên tập test bằng bốn chỉ số MAE, RMSE, MAPE và sMAPE. Kết quả thực nghiệm cho thấy GRU đạt kết quả tốt nhất theo MAE và RMSE, trong khi Random Forest đạt kết quả tốt nhất theo MAPE và sMAPE. Điều này cho thấy các mô hình có khả năng khai thác thông tin đa biến và phụ

thuộc thời gian cho kết quả tốt hơn so với các baseline đơn giản.

Thông qua đề án, nhóm đã xây dựng được một pipeline dự báo nhu cầu thuê xe đạp theo giờ bằng chuỗi thời gian nhiều chiều, đồng thời rút ra được vai trò quan trọng của feature engineering, việc tránh data leakage và nguyên tắc chia dữ liệu theo thứ tự thời gian trong các bài toán dự báo chuỗi thời gian.

Từ khóa: *Chuỗi thời gian nhiều chiều, dự báo nhu cầu thuê xe đạp, UCI Bike Sharing Dataset, Fourier features, lag features, Random Forest, GRU.*

Mục lục

Chương 1 Tổng quan đề tài	12
1.1 Đặt vấn đề	12
1.2 Lý do chọn đề tài	14
1.3 Mục tiêu nghiên cứu	14
1.3.1 Mục tiêu tổng quát	14
1.3.2 Mục tiêu cụ thể	15
1.4 Đối tượng và phạm vi nghiên cứu	15
1.4.1 Đối tượng nghiên cứu	15
1.4.2 Phạm vi nghiên cứu	16
1.5 Phương pháp nghiên cứu	16
1.5.1 Phương pháp nghiên cứu lý thuyết	16
1.5.2 Phương pháp thực nghiệm	17
1.6 Ý nghĩa khoa học và thực tiễn	17
1.6.1 Ý nghĩa khoa học	17
1.6.2 Ý nghĩa thực tiễn	18
Chương 2 Cơ sở lý thuyết và các nghiên cứu liên quan	19
2.1 Bài toán dự báo chuỗi thời gian nhiều chiều	19

2.2	Đặc điểm của dữ liệu chuỗi thời gian	20
2.2.1	Xu hướng	20
2.2.2	Tính mùa vụ	20
2.2.3	Nhiều	21
2.2.4	Phụ thuộc thời gian	21
2.3	Đặc trưng trong dự báo chuỗi thời gian	21
2.4	Rò rỉ dữ liệu trong dự báo chuỗi thời gian	22
2.5	Các nhóm mô hình dự báo chuỗi thời gian	23
2.5.1	Mô hình baseline	23
2.5.2	Mô hình học máy truyền thống	23
2.5.3	Mô hình học sâu cho dữ liệu tuần tự	24
2.6	Các độ đo đánh giá mô hình	24
2.6.1	MAE	24
2.6.2	RMSE	25
2.6.3	MAPE	25
2.6.4	sMAPE	25
2.7	Các nghiên cứu liên quan	26
2.7.1	iTransformer	26
2.7.2	TimeMixer	26
2.7.3	xLSTM-Mixer	27
2.8	Liên hệ lý thuyết với hướng thực nghiệm của nhóm	27
Chương 3 Dữ liệu và phân tích khám phá		29
3.1	Giới thiệu bộ dữ liệu	29

3.2	Mô tả các biến trong dữ liệu	30
3.3	Thống kê mô tả biến mục tiêu	31
3.4	Kiểm tra dữ liệu thiếu	33
3.5	Kiểm tra tần suất lấy mẫu	33
3.6	Phân tích biến động nhu cầu theo thời gian	34
3.7	Phân tích nhu cầu theo giờ trong ngày	35
3.8	Phân tích nhu cầu theo ngày trong tuần	35
3.9	Phân tích nhu cầu theo mùa	36
3.10	Phân tích tương quan giữa các biến	37
3.11	Nhận xét sau phân tích khám phá	38
Chương 4 Tiền xử lý dữ liệu và tạo đặc trưng		40
4.1	Mục tiêu tiền xử lý	40
4.2	Quy trình xử lý tổng quát	40
4.3	Kiểm tra dữ liệu thiếu	41
4.4	Kiểm tra tần suất lấy mẫu	41
4.5	Xử lý ngoại lai	42
4.6	Tạo đặc trưng thời gian	43
4.7	Tạo đặc trưng chu kỳ bằng Fourier features	44
4.8	Tạo đặc trưng trễ	45
4.9	Tạo đặc trưng thống kê trượt	46
4.10	Loại bỏ biến gây rò rỉ dữ liệu	47
4.11	Xử lý các dòng thiếu do tạo đặc trưng trễ	48
4.12	Chia tập train, validation và test	48

4.13 Chuẩn hóa dữ liệu	49
4.14 Tập đặc trưng sau tiền xử lý	50
Chương 5 Xây dựng mô hình	51
5.1 Mục tiêu xây dựng mô hình	51
5.2 Thiết kế bài toán dự báo	52
5.3 Các nhóm đặc trưng sử dụng	53
5.4 Nguyên tắc chia dữ liệu	54
5.5 Mô hình Naive Forecast	54
5.6 Mô hình Moving Average	55
5.7 Mô hình Linear Regression	55
5.8 Mô hình Random Forest	56
5.9 Mô hình GRU	57
5.10 Cấu hình thực nghiệm của mô hình GRU	58
5.11 Chuẩn hóa dữ liệu	59
5.12 Quy trình thực nghiệm	59
Chương 6 Kết quả thực nghiệm và đánh giá	61
6.1 Thiết lập đánh giá	61
6.2 Kết quả thực nghiệm	62
6.3 Phân tích kết quả	62
6.4 Trực quan hóa kết quả dự báo	64
6.5 Quá trình huấn luyện GRU	65
6.6 So sánh tổng quát các mô hình	65

Chương 7 Kết luận và hướng phát triển	67
7.1 Kết luận chung	67
7.2 Kết quả đạt được	68
7.3 Đóng góp của đề án	69
7.4 Hạn chế của đề án	69
7.5 Hướng phát triển	70
7.6 Kết luận cuối cùng	71
Tài liệu tham khảo	72

Danh sách hình vẽ

1.1	Biến động nhu cầu thuê xe đạp theo thời gian	13
3.1	Phân phối số lượng xe được thuê theo giờ	32
3.2	Biến động nhu cầu thuê xe theo thời gian	34
3.3	Nhu cầu thuê xe trung bình theo giờ trong ngày	35
3.4	Nhu cầu thuê xe theo ngày trong tuần	36
3.5	Nhu cầu thuê xe theo mùa	37
3.6	Ma trận tương quan giữa các biến	38
4.1	Boxplot của biến mục tiêu <code>cnt</code> trước và sau xử lý ngoại lai	43
4.2	Biểu diễn chu kỳ thời gian bằng Fourier features	45
4.3	Quan hệ giữa các đặc trưng trễ và biến mục tiêu <code>cnt</code>	46
4.4	Minh họa rolling mean và rolling standard deviation	47
4.5	Chia dữ liệu train, validation và test theo thứ tự thời gian	49
4.6	Phân phối một số đặc trưng trước và sau chuẩn hóa	50
6.1	So sánh giá trị thực tế và giá trị dự báo trên tập test	64
6.2	Đường cong huấn luyện của mô hình GRU	65

Danh sách bảng

3.1	Thông tin tổng quan về bộ dữ liệu	30
3.2	Mô tả các biến chính trong dữ liệu	31
3.3	Thống kê mô tả biến mục tiêu <code>cnt</code>	32
3.4	Kết quả kiểm tra missing values	33
4.1	Kết quả kiểm tra missing values	41
4.2	Các đặc trưng thời gian được tạo	43
4.3	Các đặc trưng trễ được tạo	45
4.4	Các đặc trưng thống kê trượt được tạo	46
4.5	Kích thước dữ liệu sau tiền xử lý	48
4.6	Số lượng quan sát trong từng tập dữ liệu	49
4.7	Các nhóm đặc trưng sau tiền xử lý	50
5.1	Các nhóm đặc trưng đầu vào của mô hình	53
5.2	Cấu hình mô hình GRU	58
5.3	Tóm tắt quy trình thực nghiệm	60
6.1	Kết quả đánh giá các mô hình trên tập test	62
6.2	So sánh tổng quát các mô hình	66

Chương 1

Tổng quan đề tài

1.1 Đặt vấn đề

Chuỗi thời gian là dạng dữ liệu trong đó các quan sát được ghi nhận theo thứ tự thời gian. Trong thực tế, nhiều bài toán dự báo không chỉ phụ thuộc vào giá trị quá khứ của biến mục tiêu, mà còn chịu tác động đồng thời bởi nhiều yếu tố bên ngoài. Đây là đặc điểm điển hình của bài toán chuỗi thời gian nhiều chiều.

Trong hệ thống chia sẻ xe đạp, nhu cầu thuê xe thay đổi theo nhiều yếu tố như giờ trong ngày, ngày trong tuần, ngày nghỉ, mùa trong năm, nhiệt độ, độ ẩm, tốc độ gió và tình trạng thời tiết. Chẳng hạn, nhu cầu thuê xe có thể tăng vào các khung giờ đi làm hoặc tan tầm, giảm khi thời tiết xấu và thay đổi rõ rệt giữa ngày làm việc với cuối tuần. Vì vậy, việc dự báo nhu cầu thuê xe không thể chỉ dựa vào một biến duy nhất, mà cần khai thác đồng thời nhiều biến đầu vào.


Bài toán của nhóm được xác định là dự báo số lượng xe đạp được thuê trong giờ tiếp theo dựa trên dữ liệu lịch sử nhiều chiều. Dạng bài toán được biểu diễn như sau:

$$X_{t-L+1:t} \in \mathbb{R}^{L \times d}, \quad y_{t+h} \in \mathbb{R}$$

Trong đó:

- L là độ dài cửa sổ lịch sử đầu vào.
- d là số biến đầu vào.
- h là khoảng dự báo.
- y là biến mục tiêu cần dự báo, trong đề tài này là biến cnt .

Trong phạm vi đề án, nhóm sử dụng cửa sổ lịch sử $L = 24$ giờ và dự báo trước $h = 1$ giờ. Điều này có nghĩa là mô hình sử dụng thông tin của 24 giờ gần nhất để dự báo tổng số xe được thuê trong giờ tiếp theo.



Hình 1.1: Biến động nhu cầu thuê xe đạp theo thời gian

Hình 1.1 cho thấy nhu cầu thuê xe biến động theo thời gian và có các mẫu dao động rõ rệt. Điều này cho thấy bài toán có tính mùa vụ và phù hợp để áp dụng các phương pháp dự báo chuỗi thời gian.

1.2 Lý do chọn đề tài

Nhóm lựa chọn đề tài “Dự báo nhu cầu thuê xe đạp theo giờ sử dụng mô hình chuỗi thời gian nhiều chiều” vì đề tài đáp ứng đồng thời yêu cầu học thuật của môn học và có ý nghĩa thực tiễn rõ ràng. Về mặt dữ liệu, bài toán có đầu vào là chuỗi thời gian nhiều chiều và đầu ra là một biến mục tiêu một chiều, phù hợp với định hướng của bài tập nhóm. Bộ dữ liệu UCI Bike Sharing Dataset là bộ dữ liệu công khai, có cấu trúc rõ ràng, được sử dụng phổ biến trong các nghiên cứu và bài toán thực nghiệm về dự báo nhu cầu.

Về mặt thực tiễn, dự báo nhu cầu thuê xe có thể hỗ trợ các hệ thống chia sẻ xe đạp trong việc điều phối phương tiện, giảm tình trạng thiếu xe tại các thời điểm cao điểm hoặc dư thừa xe tại những thời điểm nhu cầu thấp. Nhu cầu thuê xe cũng có tính mùa vụ rõ ràng theo giờ, ngày trong tuần và điều kiện thời tiết, do đó phù hợp để phân tích bằng các phương pháp chuỗi thời gian.

Ngoài ra, bài toán đủ đơn giản để xây dựng các mô hình baseline, nhưng cũng đủ phức tạp để thử nghiệm các phương pháp học máy và học sâu. Điều này giúp nhóm có thể so sánh nhiều hướng tiếp cận khác nhau, từ các mô hình đơn giản đến mô hình có khả năng học quan hệ tuần tự trong dữ liệu.

1.3 Mục tiêu nghiên cứu

1.3.1 Mục tiêu tổng quát

Mục tiêu tổng quát của đề tài là xây dựng một quy trình dự báo nhu cầu thuê xe đạp theo giờ dựa trên dữ liệu chuỗi thời gian nhiều chiều, đồng thời so sánh hiệu quả của các mô hình dự báo khác nhau. Thông qua đó, nhóm đánh giá được vai trò của tiền xử lý dữ liệu, tạo đặc trưng, lựa chọn mô hình và phương pháp đánh giá trong một bài toán dự báo thực tế.

1.3.2 Mục tiêu cụ thể

Các mục tiêu cụ thể của nhóm bao gồm:

- Tìm hiểu và tóm tắt ba bài báo mới liên quan đến dự báo chuỗi thời gian nhiều chiều.
- Phân tích bộ dữ liệu UCI Bike Sharing Dataset và xác định đặc điểm của bài toán dự báo nhu cầu thuê xe theo giờ.
- Thực hiện tiền xử lý dữ liệu, bao gồm kiểm tra dữ liệu thiếu, tần suất lấy mẫu, ngoại lai và chuẩn hóa dữ liệu.
- Xây dựng hệ đặc trưng đầu vào gồm đặc trưng thời gian, đặc trưng chu kỳ, đặc trưng trễ và đặc trưng thống kê trượt.
- Chia dữ liệu theo thứ tự thời gian thành tập huấn luyện, tập validation và tập kiểm tra.
- Huấn luyện và so sánh các mô hình dự báo từ baseline, mô hình học máy truyền thống đến mô hình học sâu.
- Đánh giá mô hình bằng các chỉ số MAE, RMSE, MAPE, sMAPE và trực quan hóa kết quả dự báo.

1.4 Đối tượng và phạm vi nghiên cứu

1.4.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là chuỗi thời gian nhu cầu thuê xe đạp theo giờ. Biến mục tiêu cần dự báo là `cnt`, biểu thị tổng số xe được thuê trong một giờ.

Các biến đầu vào được chia thành ba nhóm chính. Nhóm thứ nhất là các biến thời gian như giờ, ngày trong tuần, tháng, mùa và ngày nghỉ. Nhóm thứ

hai là các biến thời tiết như nhiệt độ, độ ẩm, tốc độ gió và tình trạng thời tiết. Nhóm thứ ba là các biến lịch sử được xây dựng từ nhu cầu thuê xe trong quá khứ, bao gồm các đặc trưng trễ và đặc trưng thống kê trượt.

1.4.2 Phạm vi nghiên cứu

Trong phạm vi đề án, nhóm tập trung vào dữ liệu theo giờ của bộ dữ liệu UCI Bike Sharing Dataset. Dữ liệu được ghi nhận trong giai đoạn từ năm 2011 đến năm 2012 và mô tả nhu cầu thuê xe cùng với các thông tin liên quan đến thời gian, thời tiết và điều kiện vận hành.

Đề tài tập trung vào bài toán dự báo tổng số lượt thuê xe theo giờ, không xét đến dự báo theo từng trạm riêng lẻ do bộ dữ liệu không cung cấp thông tin vị trí trạm. Các mô hình hiện đại như iTransformer, TimeMixer và xLSTM-Mixer được sử dụng làm cơ sở tham khảo về mặt ý tưởng, trong khi phần thực nghiệm tập trung vào các mô hình phù hợp với phạm vi triển khai của nhóm, bao gồm baseline, mô hình học máy truyền thống và mô hình học sâu GRU.

1.5 Phương pháp nghiên cứu

Nhóm kết hợp hai hướng nghiên cứu chính: nghiên cứu lý thuyết và nghiên cứu thực nghiệm.

1.5.1 Phương pháp nghiên cứu lý thuyết

Ở phần nghiên cứu lý thuyết, nhóm tìm hiểu các hướng tiếp cận mới trong dự báo chuỗi thời gian nhiều chiều thông qua ba bài báo tiêu biểu:

- **iTransformer:** khai thác ý tưởng xem mỗi biến trong chuỗi thời gian nhiều chiều như một token để học quan hệ giữa các biến.
- **TimeMixer:** tập trung vào việc trộn thông tin đa thang đo, đồng thời khai

thác xu hướng và mùa vụ trong chuỗi thời gian.

- **xLSTM-Mixer:** kết hợp thông tin theo thời gian và giữa các biến thông qua cơ chế bộ nhớ mở rộng của xLSTM.

Các bài báo này giúp nhóm xác định rằng bài toán dự báo nhu cầu thuê xe cần chú trọng cả quan hệ giữa các biến đầu vào và các cấu trúc mùa vụ theo nhiều thang thời gian.

1.5.2 Phương pháp thực nghiệm

Ở phần thực nghiệm, nhóm xây dựng một quy trình dự báo gồm các bước chính: phân tích dữ liệu, tiền xử lý, tạo đặc trưng, chia dữ liệu theo thời gian, huấn luyện mô hình và đánh giá kết quả. Quy trình này được thiết kế nhằm đảm bảo các mô hình được so sánh trong cùng điều kiện.

Các mô hình được lựa chọn theo ba mức độ. Nhóm baseline gồm Naive Forecast và Moving Average, đóng vai trò mốc so sánh ban đầu. Nhóm mô hình học máy truyền thống gồm Linear Regression và Random Forest, giúp đánh giá hiệu quả của hệ đặc trưng đã xây dựng. Nhóm mô hình học sâu sử dụng GRU nhằm học quan hệ tuần tự trong chuỗi thời gian.

Quy trình tổng quát của đề tài có thể mô tả như sau:

Raw Data → EDA → Feature Engineering → Train/Validation/Test Split → Model Training

1.6 Ý nghĩa khoa học và thực tiễn

1.6.1 Ý nghĩa khoa học

Đề tài giúp nhóm vận dụng các kiến thức về chuỗi thời gian nhiều chiều, tiền xử lý dữ liệu, tạo đặc trưng, học máy và học sâu vào một bài toán thực tế.

Việc so sánh nhiều mô hình với mức độ phức tạp khác nhau giúp làm rõ vai trò của baseline, mô hình tuyến tính, mô hình phi tuyến và mô hình tuần tự trong dự báo chuỗi thời gian.

Bên cạnh đó, đề tài cũng giúp nhóm hiểu rõ hơn ảnh hưởng của các đặc trưng thời gian, đặc trưng chu kỳ và đặc trưng trễ đối với chất lượng dự báo. Đây là những yếu tố quan trọng trong nhiều bài toán chuỗi thời gian nhiều chiều, không chỉ riêng bài toán thuê xe đạp.

1.6.2 Ý nghĩa thực tiễn

Kết quả dự báo nhu cầu thuê xe có thể hỗ trợ các hệ thống chia sẻ xe đạp trong việc dự đoán nhu cầu sử dụng xe ở các khung giờ tiếp theo, từ đó đưa ra kế hoạch điều phối phương tiện phù hợp hơn. Việc dự báo tốt giúp giảm tình trạng thiếu xe vào giờ cao điểm, hạn chế dư thừa xe ở các thời điểm nhu cầu thấp và hỗ trợ quyết định vận hành dựa trên dữ liệu.

Mặc dù đề án được thực hiện trên một bộ dữ liệu công khai, quy trình nghiên cứu có thể được mở rộng cho các bài toán dự báo nhu cầu khác như giao thông, logistics, tiêu thụ điện hoặc nhu cầu sản phẩm theo thời gian.

Chương 2

Cơ sở lý thuyết và các nghiên cứu liên quan

2.1 Bài toán dự báo chuỗi thời gian nhiều chiều

Chuỗi thời gian là một dãy các quan sát được ghi nhận theo thứ tự thời gian. Trong bài toán chuỗi thời gian một chiều, tại mỗi thời điểm chỉ có một biến được quan sát. Ngược lại, trong chuỗi thời gian nhiều chiều, tại mỗi thời điểm có nhiều biến cùng được ghi nhận. Các biến này có thể bao gồm biến mục tiêu cần dự báo và các biến giải thích có liên quan.

Giả sử tại thời điểm t , vector đặc trưng đầu vào được biểu diễn như sau:

$$x_t = [x_{t,1}, x_{t,2}, \dots, x_{t,d}]$$

Trong đó, d là số biến đầu vào. Khi xét một cửa sổ lịch sử có độ dài L , dữ liệu đầu vào có dạng:

$$X_{t-L+1:t} \in \mathbb{R}^{L \times d}$$

Mục tiêu của bài toán là dự báo một biến mục tiêu một chiều tại thời điểm tương lai:

$$y_{t+h} \in \mathbb{R}$$

Trong đề tài này, biến mục tiêu là **cnt**, biểu thị tổng số xe đạp được thuê trong một giờ. Bài toán cụ thể được xác định là sử dụng thông tin của 24 giờ gần nhất để dự báo nhu cầu thuê xe trong giờ tiếp theo:

$$X_{t-23:t} \rightarrow y_{t+1}$$

Cách biểu diễn này cho thấy đây là bài toán dự báo chuỗi thời gian nhiều chiều với đầu vào gồm nhiều biến theo thời gian và đầu ra là một biến mục tiêu duy nhất.

2.2 Đặc điểm của dữ liệu chuỗi thời gian

Dữ liệu chuỗi thời gian có một số đặc điểm quan trọng khiến việc dự báo trở nên khác biệt so với các bài toán dữ liệu dạng bảng thông thường.

2.2.1 Xu hướng

Xu hướng thể hiện sự thay đổi dài hạn của chuỗi theo thời gian. Trong một số bài toán, giá trị quan sát có thể tăng hoặc giảm dần do sự thay đổi trong hành vi người dùng, điều kiện vận hành hoặc môi trường bên ngoài. Đối với bài toán thuê xe đạp, xu hướng có thể phản ánh sự thay đổi về mức độ sử dụng hệ thống qua các giai đoạn khác nhau.

2.2.2 Tính mùa vụ

Tính mùa vụ là các mẫu lặp lại theo chu kỳ cố định. Trong bài toán thuê xe đạp, tính mùa vụ có thể xuất hiện theo nhiều thang thời gian khác nhau, chẳng hạn chu kỳ trong ngày, chu kỳ trong tuần và chu kỳ theo mùa trong năm. Ví dụ,

nhu cầu thuê xe thường khác nhau giữa giờ cao điểm và ban đêm, giữa ngày làm việc và cuối tuần, hoặc giữa các mùa có điều kiện thời tiết khác nhau.

2.2.3 Nhiễu

Nhiễu là các biến động ngẫu nhiên khó dự báo. Các yếu tố như thay đổi thời tiết đột ngột, sự kiện đặc biệt hoặc nhu cầu phát sinh ngoài quy luật có thể làm chuỗi thời gian biến động mạnh. Nhiễu khiến mô hình khó học được quy luật ổn định và có thể làm tăng sai số dự báo.

2.2.4 Phụ thuộc thời gian

Trong chuỗi thời gian, giá trị hiện tại thường có liên hệ với các giá trị trong quá khứ. Đối với nhu cầu thuê xe theo giờ, số lượt thuê ở thời điểm hiện tại có thể chịu ảnh hưởng từ các giờ liền trước, cùng giờ của ngày hôm trước hoặc cùng giờ của tuần trước. Vì vậy, việc khai thác thông tin lịch sử là yếu tố quan trọng trong thiết kế mô hình dự báo.

2.3 Đặc trưng trong dự báo chuỗi thời gian

Đặc trưng trong bài toán chuỗi thời gian không chỉ mô tả trạng thái tại một thời điểm, mà còn cần phản ánh được bối cảnh thời gian và thông tin lịch sử. Việc xây dựng đặc trưng phù hợp giúp mô hình học tốt hơn các quy luật lặp lại, xu hướng và quan hệ giữa các biến.

Các nhóm đặc trưng thường gặp trong dự báo chuỗi thời gian gồm:

- **Đặc trưng thời gian:** biểu diễn thông tin như giờ trong ngày, ngày trong tuần, tháng trong năm, ngày nghỉ hoặc cuối tuần.
- **Đặc trưng chu kỳ:** biểu diễn các biến thời gian có tính tuần hoàn bằng các hàm sin và cos, giúp mô hình hiểu được quan hệ gần nhau giữa điểm

đầu và điểm cuối của một chu kỳ.

- **Đặc trưng trễ:** sử dụng các giá trị trong quá khứ của biến mục tiêu hoặc biến đầu vào để đưa thông tin lịch sử vào mô hình.
- **Đặc trưng thống kê trượt:** mô tả xu hướng cục bộ và mức độ biến động gần đây thông qua trung bình trượt, độ lệch chuẩn trượt hoặc các thống kê tương tự.
- **Biến ngoại sinh:** là các yếu tố bên ngoài có thể ảnh hưởng đến biến mục tiêu, chẳng hạn nhiệt độ, độ ẩm, tốc độ gió hoặc tình trạng thời tiết.

Trong đề tài này, các nhóm đặc trưng trên được sử dụng nhằm giúp mô hình khai thác đồng thời thông tin thời gian, điều kiện thời tiết và lịch sử nhu cầu thuê xe.

2.4 Rò rỉ dữ liệu trong dự báo chuỗi thời gian

Rò rỉ dữ liệu xảy ra khi thông tin không nên có tại thời điểm dự báo lại được đưa vào mô hình trong quá trình huấn luyện hoặc đánh giá. Trong bài toán chuỗi thời gian, đây là một lỗi nghiêm trọng vì nó làm kết quả đánh giá trở nên quá tốt một cách giả tạo và không phản ánh đúng khả năng dự báo trên dữ liệu tương lai.

Có hai dạng rò rỉ dữ liệu thường gặp trong chuỗi thời gian. Dạng thứ nhất là rò rỉ do sử dụng biến đầu vào chứa thông tin trực tiếp về biến mục tiêu. Dạng thứ hai là rò rỉ do chia dữ liệu sai cách, chẳng hạn chia ngẫu nhiên khiến dữ liệu tương lai xuất hiện trong tập huấn luyện.

Trong bộ dữ liệu Bike Sharing, hai biến `casual` và `registered` thỏa mãn quan hệ:

$$\text{casual} + \text{registered} = \text{cnt}$$

Vì `cnt` là biến mục tiêu cần dự báo, việc sử dụng `casual` và `registered` làm đầu vào sẽ khiến mô hình gần như biết trước kết quả. Do đó, hai biến này cần được loại bỏ khỏi tập đặc trưng.

Ngoài ra, dữ liệu cần được chia theo đúng thứ tự thời gian. Tập huấn luyện phải nằm trước tập validation và tập test về mặt thời gian. Cách chia này đảm bảo mô hình chỉ học từ dữ liệu quá khứ và được đánh giá trên dữ liệu tương lai, phù hợp với bối cảnh dự báo thực tế.

2.5 Các nhóm mô hình dự báo chuỗi thời gian

Trong dự báo chuỗi thời gian, có nhiều nhóm mô hình khác nhau tùy theo mức độ phức tạp và cách khai thác thông tin thời gian. Trong đề tài này, các mô hình được chia thành ba nhóm chính.

2.5.1 Mô hình baseline

Mô hình baseline là các phương pháp đơn giản được sử dụng làm mốc so sánh ban đầu. Các mô hình như Naive Forecast hoặc Moving Average không yêu cầu quá trình học phức tạp nhưng có ý nghĩa quan trọng trong đánh giá. Một mô hình nâng cao chỉ thực sự có giá trị nếu cải thiện được kết quả so với các baseline đơn giản này.

2.5.2 Mô hình học máy truyền thống

Các mô hình học máy truyền thống như Linear Regression và Random Forest thường xem mỗi quan sát là một mẫu dữ liệu dạng bảng. Để các mô hình này khai thác được thông tin thời gian, cần xây dựng thêm các đặc trưng như biến thời gian, đặc trưng chu kỳ, đặc trưng trễ và đặc trưng thống kê trượt.

Ưu điểm của nhóm mô hình này là dễ triển khai, tốc độ huấn luyện tương đối nhanh và phù hợp với dữ liệu có cấu trúc rõ ràng. Tuy nhiên, khả năng học

quan hệ tuần tự theo thời gian phụ thuộc nhiều vào chất lượng của quá trình tạo đặc trưng.

2.5.3 Mô hình học sâu cho dữ liệu tuần tự

Các mô hình học sâu cho dữ liệu tuần tự như RNN, LSTM và GRU được thiết kế để xử lý dữ liệu có thứ tự thời gian. Thay vì chỉ xét từng quan sát độc lập, các mô hình này có khả năng học thông tin từ một chuỗi các thời điểm liên tiếp thông qua trạng thái ẩn.

Trong phạm vi đề tài, nhóm sử dụng GRU vì mô hình này có khả năng học phụ thuộc thời gian, đồng thời có cấu trúc gọn hơn so với LSTM. GRU phù hợp với bài toán dự báo nhu cầu thuê xe theo giờ, trong đó các quan sát gần nhau theo thời gian thường có liên hệ đáng kể với nhau.

2.6 Các độ đo đánh giá mô hình

Để đánh giá chất lượng dự báo, nhóm sử dụng bốn chỉ số gồm MAE, RMSE, MAPE và sMAPE. Việc sử dụng nhiều chỉ số giúp đánh giá mô hình từ nhiều góc nhìn khác nhau, bao gồm sai số tuyệt đối, sai số bình phương và sai số tương đối.

2.6.1 MAE

MAE, viết tắt của Mean Absolute Error, đo sai số tuyệt đối trung bình giữa giá trị thực tế và giá trị dự báo:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

MAE có cùng đơn vị với biến mục tiêu nên dễ diễn giải. Trong bài toán này, MAE cho biết trung bình mô hình dự báo lệch bao nhiêu lượt thuê xe so với

thực tế.

2.6.2 RMSE

RMSE, viết tắt của Root Mean Squared Error, được tính như sau:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

RMSE phạt nặng các sai số lớn hơn MAE do sai số được bình phương trước khi lấy trung bình. Vì vậy, RMSE hữu ích khi cần đánh giá khả năng hạn chế các dự báo lệch lớn.

2.6.3 MAPE

MAPE, viết tắt của Mean Absolute Percentage Error, đo sai số theo phần trăm:

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

MAPE dễ hiểu vì biểu diễn sai số dưới dạng phần trăm. Tuy nhiên, chỉ số này có hạn chế khi giá trị thực tế y_i nhỏ, vì mẫu số nhỏ có thể làm sai số phần trăm tăng rất mạnh.

2.6.4 sMAPE

sMAPE, viết tắt của Symmetric Mean Absolute Percentage Error, được tính như sau:

$$sMAPE = \frac{100\%}{n} \sum_{i=1}^n \frac{2|y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|}$$

So với MAPE, sMAPE thường ổn định hơn trong một số trường hợp vì xét đồng thời độ lớn của giá trị thực tế và giá trị dự báo. Trong bài toán có nhiều thời điểm nhu cầu thấp, sMAPE là chỉ số hữu ích để bổ sung cho MAPE.

2.7 Các nghiên cứu liên quan

Các nghiên cứu gần đây về dự báo chuỗi thời gian nhiều chiều cho thấy xu hướng khai thác đồng thời quan hệ theo thời gian, quan hệ giữa các biến và cấu trúc mùa vụ ở nhiều thang đo khác nhau. Trong phạm vi đề tài, nhóm tập trung tìm hiểu ba bài báo tiêu biểu gồm iTransformer, TimeMixer và xLSTM-Mixer.

2.7.1 iTransformer

Bài báo “*iTransformer: Inverted Transformers Are Effective for Time Series Forecasting*” đề xuất cách đảo ngược cách biểu diễn dữ liệu trong Transformer cho chuỗi thời gian nhiều chiều. Trong Transformer truyền thống, mỗi token thường đại diện cho thông tin tại một thời điểm. Tuy nhiên, với chuỗi thời gian nhiều chiều, cách biểu diễn này có thể làm trộn lẫn các biến có bản chất khác nhau.

iTransformer đề xuất xem toàn bộ chuỗi lịch sử của từng biến là một token. Nhờ đó, cơ chế attention tập trung hơn vào việc học quan hệ giữa các biến. Ý tưởng này phù hợp với bài toán của nhóm vì nhu cầu thuê xe chịu ảnh hưởng đồng thời từ nhiều biến như thời gian, nhiệt độ, độ ẩm, gió và tình trạng thời tiết.

2.7.2 TimeMixer

Bài báo “*TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting*” tập trung vào việc khai thác thông tin đa thang đo trong chuỗi thời gian. TimeMixer cho rằng dữ liệu chuỗi thời gian thường chứa đồng thời thông tin

ngắn hạn, xu hướng dài hạn và mùa vụ ở nhiều thang thời gian khác nhau.

Mô hình sử dụng cơ chế phân rã và trộn thông tin giữa các thang đo để cải thiện khả năng dự báo. Ý tưởng này có liên hệ trực tiếp với bài toán thuê xe đạp vì nhu cầu thuê xe có thể chịu ảnh hưởng bởi cả biến động ngắn hạn theo giờ, chu kỳ theo ngày, chu kỳ theo tuần và mùa trong năm.

2.7.3 xLSTM-Mixer

Bài báo “*xLSTM-Mixer: Multivariate Time Series Forecasting by Mixing via Scalar Memories*” nghiên cứu cách kết hợp thông tin theo thời gian và thông tin giữa các biến trong dự báo chuỗi thời gian nhiều chiều. Mô hình kết hợp dự báo tuyến tính, kiến trúc mixing và xLSTM để xử lý dữ liệu tuần tự nhiều chiều.

Trong phạm vi đề án, xLSTM-Mixer được sử dụng như một hướng tham khảo về mặt ý tưởng, đặc biệt ở khả năng kết hợp thông tin theo thời gian và giữa các biến. Phần thực nghiệm của nhóm tập trung vào mô hình GRU, một kiến trúc tuần tự phù hợp hơn với quy mô triển khai của đề tài.

2.8 Liên hệ lý thuyết với hướng thực nghiệm của nhóm

Từ các cơ sở lý thuyết và nghiên cứu liên quan, nhóm rút ra một số định hướng cho phần thực nghiệm.

Thứ nhất, bài toán cần được tiếp cận theo hướng chuỗi thời gian nhiều chiều thay vì chỉ sử dụng lịch sử của riêng biến cnt . Điều này xuất phát từ thực tế nhu cầu thuê xe chịu ảnh hưởng đồng thời bởi nhiều yếu tố như thời gian, thời tiết và điều kiện vận hành.

Thứ hai, cần biểu diễn tốt các yếu tố mùa vụ và chu kỳ. Các nghiên cứu như TimeMixer nhấn mạnh vai trò của thông tin đa thang đo, trong khi dữ liệu thuê xe có nhiều chu kỳ tự nhiên theo giờ, ngày và tuần. Vì vậy, việc sử dụng đặc trưng chu kỳ, đặc trưng trễ và đặc trưng thống kê trượt là cần thiết.

Thứ ba, cần tránh rò rỉ dữ liệu trong toàn bộ quy trình thực nghiệm. Việc loại bỏ các biến có quan hệ trực tiếp với biến mục tiêu và chia dữ liệu theo thứ tự thời gian giúp kết quả đánh giá phản ánh đúng hơn khả năng dự báo trên dữ liệu tương lai.

Cuối cùng, việc so sánh nhiều nhóm mô hình là cần thiết để đánh giá mức độ cải thiện giữa các hướng tiếp cận. Các baseline giúp tạo mốc so sánh, mô hình học máy truyền thống đánh giá hiệu quả của feature engineering, còn GRU giúp kiểm tra lợi ích của việc học phụ thuộc tuần tự trong chuỗi thời gian.

Chương 3

Dữ liệu và phân tích khám phá

3.1 Giới thiệu bộ dữ liệu

Trong đề án này, nhóm sử dụng bộ dữ liệu **UCI Bike Sharing Dataset**. Đây là bộ dữ liệu ghi nhận số lượng xe đạp được thuê trong một hệ thống chia sẻ xe đạp theo thời gian, đồng thời cung cấp thêm các thông tin liên quan đến lịch và thời tiết. Bộ dữ liệu phù hợp với bài toán dự báo chuỗi thời gian nhiều chiều vì tại mỗi thời điểm, nhu cầu thuê xe không chỉ phụ thuộc vào lịch sử của chính nó mà còn chịu ảnh hưởng bởi nhiều yếu tố bên ngoài.

Bộ dữ liệu gồm hai phần chính: dữ liệu tổng hợp theo ngày và dữ liệu chi tiết theo giờ. Trong phạm vi đề án, nhóm tập trung vào dữ liệu theo giờ vì mục tiêu nghiên cứu là dự báo nhu cầu thuê xe trong giờ tiếp theo. Việc sử dụng dữ liệu theo giờ giúp mô hình khai thác được các biến động ngắn hạn trong ngày, chẳng hạn sự khác biệt giữa giờ cao điểm, giờ làm việc và ban đêm.

Thông tin tổng quan về dữ liệu được trình bày trong Bảng 3.1.

Bảng 3.1: Thông tin tổng quan về bộ dữ liệu

Thuộc tính	Giá trị
Tên bộ dữ liệu	UCI Bike Sharing Dataset
Dữ liệu sử dụng	Dữ liệu theo giờ
Số dòng	17,379
Số cột ban đầu	17
Thời gian bắt đầu	2011-01-01
Thời gian kết thúc	2012-12-31
Đơn vị thời gian	Theo giờ
Biến mục tiêu	<code>cnt</code>

3.2 Mô tả các biến trong dữ liệu

Các biến trong dữ liệu có thể được chia thành ba nhóm chính: nhóm biến thời gian, nhóm biến thời tiết và nhóm biến liên quan đến số lượt thuê xe. Trong đó, biến `cnt` là biến mục tiêu cần dự báo, biểu thị tổng số lượt thuê xe trong một giờ.

Bảng 3.2: Mô tả các biến chính trong dữ liệu

Biến	Ý nghĩa
<code>instant</code>	Số thứ tự bản ghi.
<code>dteday</code>	Ngày ghi nhận dữ liệu.
<code>season</code>	Mùa trong năm.
<code>yr</code>	Năm quan sát.
<code>mnth</code>	Tháng trong năm.
<code>hr</code>	Giờ trong ngày.
<code>holiday</code>	Biến đánh dấu ngày nghỉ.
<code>weekday</code>	Ngày trong tuần.
<code>workingday</code>	Biến đánh dấu ngày làm việc.
<code>weathersit</code>	Tình trạng thời tiết.
<code>temp</code>	Nhiệt độ đã chuẩn hóa.
<code>atemp</code>	Nhiệt độ cảm nhận đã chuẩn hóa.
<code>hum</code>	Độ ẩm đã chuẩn hóa.
<code>windspeed</code>	Tốc độ gió đã chuẩn hóa.
<code>casual</code>	Số lượt thuê của người dùng chưa đăng ký.
<code>registered</code>	Số lượt thuê của người dùng đã đăng ký.
<code>cnt</code>	Tổng số lượt thuê xe trong một giờ, là biến mục tiêu cần dự báo.

Hai biến `casual` và `registered` có quan hệ trực tiếp với biến mục tiêu:

$$\text{casual} + \text{registered} = \text{cnt}$$

Do đó, nếu sử dụng hai biến này làm đầu vào, mô hình sẽ bị rò rỉ thông tin vì gần như biết trước giá trị cần dự báo. Vì lý do này, `casual` và `registered` chỉ được dùng để hiểu cấu trúc dữ liệu, không được sử dụng làm đặc trưng đầu vào trong quá trình huấn luyện mô hình.


3.3 Thống kê mô tả biến mục tiêu

Biến `cnt` biểu thị tổng số lượt thuê xe trong mỗi giờ. Thống kê mô tả của biến này được trình bày trong Bảng 3.3.

Bảng 3.3: Thống kê mô tả biến mục tiêu **cnt**

Chỉ số	Giá trị
Count	17,379
Mean	189.46
Std	181.39
Min	1
Q1	40
Median	142
Q3	281
Max	977

Có thể thấy biến **cnt** có độ biến động khá lớn. Giá trị nhỏ nhất là 1, trong khi giá trị lớn nhất đạt 977. Trung bình số lượt thuê theo giờ là 189.46, nhưng trung vị chỉ bằng 142, cho thấy phân phối của biến mục tiêu có xu hướng lệch phải. Điều này phản ánh thực tế rằng phần lớn thời điểm có nhu cầu thuê xe ở mức vừa hoặc thấp, trong khi một số thời điểm cao điểm có số lượt thuê rất lớn.



Hình 3.1: Phân phối số lượng xe được thuê theo giờ

Hình 3.1 cho thấy phân phối của biến **cnt** không đều, tập trung nhiều ở các mức nhu cầu thấp và trung bình, đồng thời có một phần đuôi kéo dài về phía các giá trị cao. Đặc điểm này cho thấy khi đánh giá mô hình, nhóm cần sử dụng kết hợp nhiều chỉ số như MAE, RMSE, MAPE và sMAPE để có cái nhìn đầy đủ hơn về sai số dự báo.

3.4 Kiểm tra dữ liệu thiếu

Trước khi xây dựng mô hình, nhóm tiến hành kiểm tra dữ liệu thiếu trên toàn bộ các cột. Kết quả cho thấy dữ liệu không có missing value ở cấp độ ô dữ liệu.

Bảng 3.4: Kết quả kiểm tra missing values

Nội dung	Giá trị
Tổng số dòng	17,379
Tổng số cột	17
Tổng số missing values	0

Việc không có missing values giúp quá trình xử lý dữ liệu thuận lợi hơn. Tuy nhiên, với dữ liệu chuỗi thời gian, ngoài việc kiểm tra giá trị thiếu trong từng cột, cần kiểm tra thêm tính liên tục của mốc thời gian để xác định dữ liệu có được lấy mẫu đều hay không.

3.5 Kiểm tra tần suất lấy mẫu


Dữ liệu được mô tả là dữ liệu theo giờ, do đó về lý thuyết các mốc thời gian nên cách nhau đều đặn một giờ. Khi kiểm tra chuỗi thời gian từ thời điểm bắt đầu đến thời điểm kết thúc, nhóm phát hiện có một số timestamp theo giờ bị thiếu. Điều này cho thấy chuỗi dữ liệu không hoàn toàn đều tuyệt đối theo thời gian.

Trong phạm vi đề án, nhóm không thực hiện nội suy để bổ sung các timestamp bị thiếu. Do số lượng timestamp bị thiếu chiếm tỷ lệ nhỏ so với tổng số quan sát, nhóm giữ nguyên thứ tự thời gian của dữ liệu và tạo đặc trưng trễ dựa trên các quan sát liên tiếp. Cách xử lý này giúp bảo toàn dữ liệu gốc, tránh đưa thêm giả định nội suy vào chuỗi thời gian và vẫn đảm bảo mô hình không sử dụng thông tin tương lai.

Kết quả kiểm tra tần suất lấy mẫu là cơ sở để nhóm chú ý hơn trong quá trình tạo đặc trưng trễ, đặc trưng thống kê trượt và chia dữ liệu theo thứ tự thời gian ở các chương sau.

3.6 Phân tích biến động nhu cầu theo thời gian

Trước khi xây dựng mô hình, nhóm trực quan hóa biến c_{nt} theo thời gian để quan sát xu hướng và dao động tổng thể của nhu cầu thuê xe.




Hình 3.2: Biến động nhu cầu thuê xe theo thời gian

Hình 3.2 cho thấy nhu cầu thuê xe thay đổi liên tục theo thời gian, với các dao động ngắn hạn và sự khác biệt rõ rệt giữa các giai đoạn. Biến động này phản ánh đặc trưng của dữ liệu chuỗi thời gian, trong đó giá trị tại một thời điểm thường có liên hệ với bối cảnh thời gian và các quan sát trước đó.

3.7 Phân tích nhu cầu theo giờ trong ngày

Giờ trong ngày là một yếu tố quan trọng đối với nhu cầu thuê xe. Trong thực tế, hành vi sử dụng xe đạp thường gắn với lịch sinh hoạt và di chuyển của người dùng, chẳng hạn đi làm, đi học, tan tầm hoặc di chuyển ngoài giờ làm việc.




Hình 3.3: Nhu cầu thuê xe trung bình theo giờ trong ngày

Từ Hình 3.3, có thể thấy nhu cầu thuê xe không phân bố đều trong ngày. Nhu cầu thường thấp vào ban đêm và tăng lên vào các khung giờ ban ngày, đặc biệt gần các thời điểm người dùng di chuyển nhiều. Điều này cho thấy biến giờ trong ngày và các đặc trưng chu kỳ theo giờ có vai trò quan trọng trong bài toán dự báo.

3.8 Phân tích nhu cầu theo ngày trong tuần

Ngoài giờ trong ngày, ngày trong tuần cũng ảnh hưởng đến nhu cầu thuê xe. Hành vi sử dụng xe trong ngày làm việc có thể khác với cuối tuần do mục đích di chuyển, lịch làm việc và hoạt động cá nhân của người dùng thay đổi.




Hình 3.4: Nhu cầu thuê xe theo ngày trong tuần

Hình 3.4 cho thấy nhu cầu thuê xe có sự khác biệt giữa các ngày trong tuần. Kết quả này cho thấy yếu tố lịch có ảnh hưởng đến hành vi thuê xe và cần được đưa vào mô hình dưới dạng các biến thời gian phù hợp.

3.9 Phân tích nhu cầu theo mùa

Yếu tố mùa vụ cũng có thể ảnh hưởng đến nhu cầu thuê xe. Trong các giai đoạn có thời tiết thuận lợi, người dùng có xu hướng sử dụng xe đạp nhiều hơn. Ngược lại, khi thời tiết lạnh, mưa hoặc điều kiện di chuyển không thuận tiện, nhu cầu có thể giảm.




Hình 3.5: Nhu cầu thuê xe theo mùa

Kết quả trong Hình 3.5 cho thấy nhu cầu thuê xe thay đổi theo mùa. Đây là cơ sở để xem xét các biến liên quan đến mùa, tháng trong năm và các đặc trưng chu kỳ khi xây dựng tập đặc trưng đầu vào.

3.10 Phân tích tương quan giữa các biến

Để xem xét mối quan hệ giữa các biến, nhóm sử dụng ma trận tương quan. Ma trận tương quan giúp nhận diện các biến có liên hệ tuyến tính với biến mục tiêu `cnt`, đồng thời hỗ trợ phát hiện các biến có khả năng trùng lặp thông tin.



Hình 3.6: Ma trận tương quan giữa các biến

Hình 3.6 cho thấy một số biến có tương quan đáng chú ý với biến mục tiêu. Các biến liên quan đến thời gian, thời tiết và nhu cầu trong quá khứ đều có thể đóng góp vào dự báo. Tuy nhiên, tương quan tuyến tính chỉ phản ánh một phần mối quan hệ giữa các biến. Trong thực tế, nhu cầu thuê xe có thể phụ thuộc vào các quan hệ phi tuyến và tương tác phức tạp, vì vậy nhóm sử dụng thêm các mô hình như Random Forest và GRU ở phần thực nghiệm.

3.11 Nhận xét sau phân tích khám phá

Từ quá trình phân tích khám phá dữ liệu, nhóm rút ra một số nhận xét chính. Thứ nhất, dữ liệu có dạng chuỗi thời gian theo giờ, phù hợp với bài toán

dự báo nhu cầu ngắn hạn. Thứ hai, biến mục tiêu **cnt** có độ biến động lớn, phản ánh sự khác biệt rõ giữa các thời điểm thấp điểm và cao điểm. Thứ ba, dữ liệu không có missing values ở cấp độ ô dữ liệu, nhưng timeline theo giờ có một số timestamp bị thiếu, do đó cần chú ý khi tạo đặc trưng trễ và chia dữ liệu.

Ngoài ra, nhu cầu thuê xe thể hiện tính mùa vụ theo nhiều thang thời gian, bao gồm giờ trong ngày, ngày trong tuần và mùa trong năm. Các biến thời gian và thời tiết đều có khả năng đóng góp vào dự báo. Hai biến **casual** và **registered** có quan hệ trực tiếp với biến mục tiêu nên không được sử dụng làm đầu vào để tránh rò rỉ dữ liệu.

Những nhận xét trên là cơ sở để nhóm thực hiện bước tiền xử lý và tạo đặc trưng trong chương tiếp theo.

Chương 4

Tiền xử lý dữ liệu và tạo đặc trưng

4.1 Mục tiêu tiền xử lý

Sau bước phân tích khám phá dữ liệu, nhóm tiến hành tiền xử lý và tạo đặc trưng nhằm đưa dữ liệu về dạng phù hợp cho quá trình huấn luyện mô hình dự báo. Đối với bài toán chuỗi thời gian, tiền xử lý không chỉ nhằm làm sạch dữ liệu mà còn phải đảm bảo giữ đúng thứ tự thời gian và tránh đưa thông tin tương lai vào mô hình.

Các bước chính trong chương này bao gồm kiểm tra dữ liệu thiếu, kiểm tra tần suất lấy mẫu, xử lý ngoại lai, tạo đặc trưng thời gian, tạo đặc trưng chu kỳ, tạo đặc trưng trễ, tạo đặc trưng thống kê trượt, loại bỏ biến gây rò rỉ dữ liệu, chia dữ liệu theo thứ tự thời gian và chuẩn hóa dữ liệu.

4.2 Quy trình xử lý tổng quát

Quy trình xử lý dữ liệu được thiết kế theo nguyên tắc các bước chỉ sử dụng thông tin hiện tại và quá khứ tại thời điểm dự báo. Điều này đặc biệt quan trọng vì nếu quá trình tiền xử lý vô tình sử dụng thông tin từ tương lai, kết quả đánh giá mô hình sẽ trở nên không đáng tin cậy.

Quy trình tổng quát được mô tả như sau:

Raw Data → Datetime Processing → Cleaning → Feature Engineering → Time-based Split →

Trong đó, bước xử lý thời gian giúp tạo trục thời gian thống nhất; bước làm sạch dữ liệu nhằm kiểm tra missing values, timestamp bị thiếu và ngoại lai; bước tạo đặc trưng giúp mô hình khai thác thông tin mùa vụ, chu kỳ và lịch sử; bước chia dữ liệu theo thời gian giúp mô phỏng đúng bối cảnh dự báo thực tế.

4.3 Kiểm tra dữ liệu thiếu

Trước hết, nhóm kiểm tra số lượng giá trị thiếu trong toàn bộ dữ liệu. Kết quả cho thấy dữ liệu không có missing values ở cấp độ ô dữ liệu.

Bảng 4.1: Kết quả kiểm tra missing values

Nội dung	Giá trị
Số dòng dữ liệu thô	17,379
Số cột dữ liệu thô	17
Tổng số missing values	0

Kết quả này cho thấy dữ liệu không cần xử lý thiếu ở từng cột. Tuy nhiên, với dữ liệu chuỗi thời gian, việc không có missing values trong bảng chưa đủ để kết luận dữ liệu hoàn toàn đầy đủ. Do đó, nhóm tiếp tục kiểm tra tính liên tục của các mốc thời gian.

4.4 Kiểm tra tần suất lấy mẫu

Dữ liệu được ghi nhận theo giờ, vì vậy về lý thuyết các mốc thời gian liên tiếp nên cách nhau đúng một giờ. Nhóm tạo cột thời gian hoàn chỉnh từ thông tin ngày và giờ, sau đó kiểm tra chuỗi thời gian từ thời điểm bắt đầu đến thời điểm kết thúc.

Kết quả cho thấy dữ liệu có một số timestamp theo giờ bị thiếu, tức là chuỗi

không hoàn toàn đều tuyệt đối. Trong phạm vi đồ án, nhóm không nội suy để bổ sung các mốc thời gian này. Lý do là số lượng timestamp bị thiếu chiếm tỷ lệ nhỏ so với toàn bộ dữ liệu, trong khi nội suy có thể tạo ra các giá trị không phản ánh đúng nhu cầu thực tế.

Thay vào đó, nhóm giữ nguyên thứ tự thời gian của các quan sát có sẵn và tạo đặc trưng trễ dựa trên các quan sát liên tiếp. Cách xử lý này giúp bảo toàn dữ liệu gốc, tránh đưa thêm giả định nội suy vào chuỗi và vẫn đảm bảo mô hình không sử dụng thông tin tương lai.


4.5 Xử lý ngoại lai

Biến mục tiêu `cnt` có độ biến động lớn, với giá trị nhỏ nhất là 1 và giá trị lớn nhất là 977. Một số giá trị quá cao hoặc quá thấp có thể ảnh hưởng đến quá trình huấn luyện mô hình, đặc biệt đối với các mô hình nhạy với sai số lớn.

Nhóm sử dụng phương pháp Winsorization theo ngưỡng phân vị 1% và 99% để xử lý ngoại lai. Thay vì xóa các dòng dữ liệu, phương pháp này giới hạn giá trị của biến mục tiêu trong một khoảng hợp lý:

$$\text{cnt}^* = \begin{cases} Q_{0.01}, & \text{nếu } \text{cnt} < Q_{0.01} \\ Q_{0.99}, & \text{nếu } \text{cnt} > Q_{0.99} \\ \text{cnt}, & \text{ngược lại} \end{cases}$$

Trong đó, $Q_{0.01}$ và $Q_{0.99}$ lần lượt là phân vị 1% và 99% của biến `cnt`. Cách làm này giúp giảm ảnh hưởng của các giá trị cực đoan nhưng vẫn giữ nguyên số lượng quan sát và thứ tự thời gian của chuỗi.



Hình 4.1: Boxplot của biến mục tiêu `cnt` trước và sau xử lý ngoại lai

Hình 4.1 minh họa sự thay đổi của phân phối biến `cnt` sau khi xử lý ngoại lai. Việc giới hạn giá trị thay vì xóa dòng là phù hợp với dữ liệu chuỗi thời gian vì xóa quan sát có thể làm thay đổi cấu trúc thời gian của chuỗi.

4.6 Tạo đặc trưng thời gian

Nhu cầu thuê xe đạp thường thay đổi theo lịch sinh hoạt của người dùng, do đó các biến thời gian có vai trò quan trọng trong bài toán dự báo. Từ thông tin ngày và giờ ban đầu, nhóm tạo thêm một số đặc trưng thời gian để mô hình khai thác tốt hơn quy luật theo giờ, ngày và tháng.

Bảng 4.2: Các đặc trưng thời gian được tạo

Biến	Ý nghĩa
<code>hour</code>	Giờ trong ngày, nhận giá trị từ 0 đến 23.
<code>day_of_week</code>	Ngày trong tuần, nhận giá trị từ 0 đến 6.
<code>month</code>	Tháng trong năm, nhận giá trị từ 1 đến 12.
<code>is_weekend</code>	Biến nhị phân, bằng 1 nếu là cuối tuần và bằng 0 trong các trường hợp còn lại.

Các đặc trưng này giúp mô hình phân biệt sự khác nhau giữa giờ cao điểm và thấp điểm, giữa ngày làm việc và cuối tuần, cũng như giữa các giai đoạn khác nhau trong năm.

4.7 Tạo đặc trưng chu kỳ bằng Fourier features

Các biến như giờ trong ngày, ngày trong tuần và tháng trong năm có tính chu kỳ. Nếu biểu diễn trực tiếp bằng số nguyên, mô hình có thể hiểu sai khoảng cách giữa các giá trị nằm gần nhau trên chu kỳ. Ví dụ, giờ 23 và giờ 0 thực tế nằm gần nhau trong chu kỳ 24 giờ, nhưng nếu biểu diễn bằng số nguyên thì khoảng cách giữa chúng là 23.

Để khắc phục vấn đề này, nhóm sử dụng Fourier features dạng sin và cos. Với một biến thời gian có chu kỳ P , cách biểu diễn được viết như sau:

$$x_{\sin} = \sin\left(\frac{2\pi x}{P}\right)$$


$$x_{\cos} = \cos\left(\frac{2\pi x}{P}\right)$$

Trong đề tài này, nhóm áp dụng cách biểu diễn trên cho chu kỳ 24 giờ, 7 ngày và 12 tháng. Cụ thể:

$$\text{hour_sin} = \sin\left(\frac{2\pi \cdot \text{hour}}{24}\right), \quad \text{hour_cos} = \cos\left(\frac{2\pi \cdot \text{hour}}{24}\right)$$

$$\text{weekday_sin} = \sin\left(\frac{2\pi \cdot \text{day_of_week}}{7}\right), \quad \text{weekday_cos} = \cos\left(\frac{2\pi \cdot \text{day_of_week}}{7}\right)$$

$$\text{month_sin} = \sin\left(\frac{2\pi \cdot \text{month}}{12}\right), \quad \text{month_cos} = \cos\left(\frac{2\pi \cdot \text{month}}{12}\right)$$



Hình 4.2: Biểu diễn chu kỳ thời gian bằng Fourier features

Hình 4.2 minh họa cách cặp sin/cos biểu diễn dữ liệu có tính tuần hoàn. Việc sử dụng Fourier features giúp mô hình nhận biết tốt hơn tính chu kỳ của nhu cầu thuê xe theo giờ, theo tuần và theo tháng.

4.8 Tạo đặc trưng trễ


Đặc trưng trễ được tạo từ các giá trị trong quá khứ của biến mục tiêu. Trong bài toán dự báo chuỗi thời gian, các giá trị quá khứ thường chứa nhiều thông tin quan trọng vì nhu cầu tại thời điểm hiện tại có thể phụ thuộc vào nhu cầu ở các thời điểm trước đó.

Nhóm sử dụng ba đặc trưng trễ đại diện cho ba thang thời gian khác nhau:

Bảng 4.3: Các đặc trưng trễ được tạo

Biến	Ý nghĩa
lag_1	Nhu cầu thuê xe ở quan sát liền trước.
lag_24	Nhu cầu thuê xe ở khoảng một ngày trước.
lag_168	Nhu cầu thuê xe ở khoảng một tuần trước.

Các đặc trưng này lần lượt phản ánh thông tin ngắn hạn, chu kỳ theo ngày và chu kỳ theo tuần. Tất cả các đặc trưng trễ được tạo bằng thao tác dịch chuỗi về quá khứ, nhờ đó tại thời điểm dự báo, mô hình chỉ sử dụng thông tin đã xảy ra trước đó.



Hình 4.3: Quan hệ giữa các đặc trưng trễ và biến mục tiêu *cnt*

Hình 4.3 cho thấy các đặc trưng trễ có quan hệ nhất định với biến mục tiêu. Điều này củng cố nhận định rằng thông tin lịch sử là thành phần quan trọng trong bài toán dự báo nhu cầu thuê xe.

4.9 Tạo đặc trưng thống kê trượt

Bên cạnh các giá trị trễ riêng lẻ, nhóm tạo thêm đặc trưng thống kê trượt để mô tả xu hướng và mức độ biến động gần đây của chuỗi. Các đặc trưng này giúp mô hình nhận biết liệu nhu cầu trong khoảng thời gian gần nhất đang ở mức cao, thấp hay biến động mạnh.

Bảng 4.4: Các đặc trưng thống kê trượt được tạo


Biến	Ý nghĩa
<code>rolling_mean_24</code>	Trung bình nhu cầu thuê xe trong 24 quan sát trước đó.
<code>rolling_std_24</code>	Độ lệch chuẩn của nhu cầu thuê xe trong 24 quan sát trước đó.

Để tránh rò rỉ dữ liệu, các đặc trưng thống kê trượt được tính trên chuỗi đã dịch một bước về quá khứ:

$$\text{rolling_mean_24}(t) = \text{mean}(y_{t-24}, \dots, y_{t-1})$$

$$\text{rolling_std_24}(t) = \text{std}(y_{t-24}, \dots, y_{t-1})$$

Như vậy, tại thời điểm dự báo t , mô hình chỉ sử dụng dữ liệu trước thời điểm t .



Hình 4.4: Minh họa rolling mean và rolling standard deviation

4.10 Loại bỏ biến gây rò rỉ dữ liệu

Trong bộ dữ liệu gốc, hai biến `casual` và `registered` có quan hệ trực tiếp với biến mục tiêu:

$$\text{casual} + \text{registered} = \text{cnt}$$

Nếu sử dụng hai biến này làm đầu vào, mô hình sẽ gần như biết trước kết quả cần dự báo. Đây là dạng rò rỉ dữ liệu nghiêm trọng và làm cho kết quả đánh giá không còn đáng tin cậy. Vì vậy, `casual` và `registered` được loại bỏ khỏi tập đặc trưng đầu vào.

Ngoài ra, các biến định danh hoặc biến thời gian thô không còn cần thiết sau khi đã tạo đặc trưng mới cũng được loại bỏ. Việc này giúp tập dữ liệu đầu

vào gọn hơn và tránh trùng lặp thông tin.

4.11 Xử lý các dòng thiếu do tạo đặc trưng trễ

Sau khi tạo các đặc trưng trễ và đặc trưng thống kê trượt, một số dòng đầu tiên sẽ bị thiếu giá trị vì chưa có đủ lịch sử để tính toán. Ví dụ, đặc trưng `lag_168` cần thông tin của 168 quan sát trước đó, nên các dòng đầu tiên không thể có giá trị hợp lệ.

Nhóm loại bỏ các dòng bị thiếu phát sinh từ quá trình tạo đặc trưng trễ và thống kê trượt. Sau bước này, dữ liệu còn 17,211 quan sát và 30 cột.

Bảng 4.5: Kích thước dữ liệu sau tiền xử lý

Nội dung	Giá trị
Số dòng dữ liệu thô	17,379
Số dòng sau tiền xử lý	17,211
Số cột sau tiền xử lý	30

4.12 Chia tập train, validation và test


Với dữ liệu chuỗi thời gian, việc chia dữ liệu cần giữ nguyên thứ tự thời gian. Nếu chia ngẫu nhiên, dữ liệu tương lai có thể xuất hiện trong tập huấn luyện, khiến kết quả đánh giá bị sai lệch. Do đó, nhóm chia dữ liệu theo thứ tự thời gian với tỷ lệ:

$$\text{Train : Validation : Test} = 70\% : 15\% : 15\%$$

Tập train được dùng để huấn luyện mô hình, tập validation được dùng để theo dõi và lựa chọn cấu hình mô hình, còn tập test được giữ riêng cho bước đánh giá cuối cùng.

Bảng 4.6: Số lượng quan sát trong từng tập dữ liệu

Tập dữ liệu	Số dòng	Tỷ lệ xấp xỉ
Train	12,047	70%
Validation	2,582	15%
Test	2,582	15%



Hình 4.5: Chia dữ liệu train, validation và test theo thứ tự thời gian

Hình 4.5 minh họa cách chia dữ liệu theo trục thời gian. Cách chia này mô phỏng đúng bối cảnh dự báo thực tế, trong đó mô hình chỉ được học từ dữ liệu quá khứ và được kiểm tra trên dữ liệu tương lai.


4.13 Chuẩn hóa dữ liệu

Chuẩn hóa dữ liệu giúp đưa các biến số về cùng thang đo, đặc biệt quan trọng với các mô hình nhạy cảm với độ lớn của đặc trưng như Linear Regression và GRU. Nhóm sử dụng phương pháp chuẩn hóa theo StandardScaler:

$$x' = \frac{x - \mu}{\sigma}$$

Trong đó, μ là trung bình của biến và σ là độ lệch chuẩn của biến. Để tránh rò rỉ dữ liệu, hai tham số này chỉ được tính trên tập train. Sau đó, cùng bộ tham số được sử dụng để biến đổi tập validation và tập test.

Cách làm này đảm bảo rằng thông tin từ validation và test không ảnh hưởng đến quá trình huấn luyện. Đối với mô hình GRU, chuẩn hóa còn giúp quá trình tối ưu ổn định hơn vì các biến đầu vào có thang đo tương đồng.



Hình 4.6: Phân phối một số đặc trưng trước và sau chuẩn hóa

4.14 Tập đặc trưng sau tiền xử lý

Sau quá trình tiền xử lý và tạo đặc trưng, dữ liệu đầu vào cho mô hình bao gồm nhiều nhóm biến khác nhau. Các nhóm đặc trưng này được trình bày trong Bảng 4.7.

Bảng 4.7: Các nhóm đặc trưng sau tiền xử lý

Nhóm đặc trưng	Các biến
Biến thời gian gốc	season, yr, mnth, hr, holiday, weekday, workingday
Biến thời tiết	weathersit, temp, atemp, hum, windspeed
Biến thời gian mở rộng	hour, day_of_week, month, is_weekend
Fourier features	hour_sin, hour_cos, weekday_sin, weekday_cos, month_sin, month_cos
Lag features	lag_1, lag_24, lag_168
Rolling features	rolling_mean_24, rolling_std_24
Biến mục tiêu	cnt

Tập đặc trưng sau tiền xử lý phản ánh đồng thời thông tin thời gian, thời tiết, chu kỳ, lịch sử và xu hướng gần đây của nhu cầu thuê xe. Đây là đầu vào cho các mô hình dự báo được trình bày ở chương tiếp theo.

Chương 5

Xây dựng mô hình

5.1 Mục tiêu xây dựng mô hình

Sau khi hoàn thành bước phân tích, tiền xử lý dữ liệu và tạo đặc trưng, nhóm tiến hành xây dựng các mô hình dự báo nhu cầu thuê xe đạp theo giờ. Mục tiêu của chương này là trình bày cách thiết kế bài toán dự báo, cấu trúc dữ liệu đầu vào - đầu ra, các nhóm mô hình được sử dụng và quy trình thực nghiệm để so sánh hiệu quả giữa các phương pháp.

Bài toán được xem xét là bài toán dự báo chuỗi thời gian nhiều chiều. Tại mỗi thời điểm, dữ liệu đầu vào bao gồm nhiều biến giải thích như thông tin thời gian, điều kiện thời tiết, đặc trưng chu kỳ và các giá trị trễ của nhu cầu thuê xe. Đầu ra của mô hình là biến mục tiêu `cnt`, biểu diễn tổng số lượt thuê xe đạp tại thời điểm cần dự báo.

Việc xây dựng nhiều nhóm mô hình khác nhau giúp đánh giá bài toán từ mức đơn giản đến phức tạp. Các mô hình baseline được sử dụng để tạo mốc so sánh ban đầu. Các mô hình học máy truyền thống giúp khai thác tập đặc trưng đã xây dựng. Cuối cùng, mô hình học sâu GRU được sử dụng nhằm học trực tiếp quan hệ phụ thuộc theo thời gian trong chuỗi dữ liệu.

5.2 Thiết kế bài toán dự báo

Với chuỗi thời gian nhiều chiều, tại mỗi thời điểm t , dữ liệu quan sát được biểu diễn dưới dạng vector đặc trưng:

$$x_t = [x_{t,1}, x_{t,2}, \dots, x_{t,d}]$$

Trong đó, d là số lượng biến đầu vào. Biến mục tiêu cần dự báo là:

$$y_t = \text{cnt}_t$$

Với các mô hình học máy dạng bảng như Linear Regression và Random Forest, mỗi dòng dữ liệu tại thời điểm t được xem là một mẫu huấn luyện độc lập sau khi đã bổ sung các đặc trưng thời gian, đặc trưng chu kỳ và đặc trưng trễ. Khi đó, mô hình học ánh xạ:

$$f(x_t) \rightarrow y_t$$

Đối với mô hình GRU, dữ liệu đầu vào được tổ chức theo dạng của sổ thời gian. Với độ dài của sổ là $L = 24$, đầu vào tại thời điểm t gồm thông tin của 24 giờ gần nhất:

$$X_{t-L+1:t} \in \mathbb{R}^{L \times d}$$

Đầu ra tương ứng là giá trị nhu cầu thuê xe ở thời điểm kế tiếp:

$$y_{t+1} \in \mathbb{R}$$

Cách thiết kế này phù hợp với bài toán dự báo theo giờ vì nhu cầu thuê xe thường phụ thuộc mạnh vào xu hướng trong ngày, các giờ liền trước và chu kỳ sinh hoạt của người dùng.

5.3 Các nhóm đặc trưng sử dụng

Dữ liệu đầu vào cho mô hình được xây dựng từ nhiều nhóm đặc trưng khác nhau. Các nhóm đặc trưng này nhằm phản ánh cả yếu tố thời gian, điều kiện môi trường và thông tin lịch sử của biến mục tiêu.

Bảng 5.1: Các nhóm đặc trưng đầu vào của mô hình

Nhóm đặc trưng	Ý nghĩa
Đặc trưng thời gian gốc	Bao gồm các biến như mùa, năm, tháng, giờ, ngày nghỉ, ngày trong tuần và ngày làm việc. Các biến này phản ánh bối cảnh thời gian của nhu cầu thuê xe.
Đặc trưng thời tiết	Bao gồm tình trạng thời tiết, nhiệt độ, nhiệt độ cảm nhận, độ ẩm và tốc độ gió. Đây là các yếu tố có ảnh hưởng trực tiếp đến quyết định thuê xe của người dùng.
Đặc trưng thời gian mở rộng	Bao gồm giờ trong ngày, thứ trong tuần, tháng trong năm và biến cuối tuần. Nhóm đặc trưng này giúp mô hình khai thác tốt hơn các quy luật lặp lại theo lịch.
Đặc trưng Fourier	Biểu diễn chu kỳ thời gian bằng các hàm sin và cos, giúp mô hình học được tính mùa vụ theo giờ, theo tuần và theo tháng một cách liên tục hơn.
Đặc trưng trễ	Bao gồm các giá trị nhu cầu thuê xe trong quá khứ, ví dụ trễ 1 giờ, 24 giờ và 168 giờ. Nhóm đặc trưng này giúp mô hình tận dụng thông tin lịch sử của chuỗi thời gian.
Đặc trưng thống kê trượt	Bao gồm trung bình trượt và độ lệch chuẩn trượt trong các cửa sổ thời gian nhất định, giúp mô hình nhận biết xu hướng và mức độ biến động gần đây.

Hai biến `casual` và `registered` không được sử dụng làm đầu vào vì tổng của hai biến này chính là biến mục tiêu `cnt`. Nếu đưa hai biến này vào mô hình, kết quả dự báo có thể bị rò rỉ thông tin và không phản ánh đúng năng lực dự báo trong thực tế.

5.4 Nguyên tắc chia dữ liệu

Do dữ liệu có bản chất chuỗi thời gian, việc chia tập dữ liệu được thực hiện theo đúng thứ tự thời gian. Nhóm không sử dụng cách chia ngẫu nhiên vì cách này có thể làm thông tin từ tương lai xuất hiện trong tập huấn luyện, dẫn đến đánh giá sai lệch.

Dữ liệu được chia thành ba phần:

Train : 70%, Validation : 15%, Test : 15%

Tập train được sử dụng để huấn luyện mô hình. Tập validation được sử dụng để theo dõi quá trình huấn luyện và lựa chọn cấu hình phù hợp, đặc biệt đối với mô hình GRU. Tập test chỉ được sử dụng ở bước đánh giá cuối cùng nhằm kiểm tra khả năng dự báo của mô hình trên dữ liệu chưa từng được sử dụng trong quá trình huấn luyện.

5.5 Mô hình Naive Forecast

Naive Forecast là mô hình baseline đơn giản nhất. Ý tưởng của mô hình là sử dụng giá trị quan sát gần nhất trong quá khứ làm dự báo cho thời điểm tiếp theo:

$$\hat{y}_{t+1} = y_t$$

Mô hình này không học tham số và không sử dụng các biến đầu vào khác ngoài giá trị gần nhất của biến mục tiêu. Tuy đơn giản, Naive Forecast vẫn có ý nghĩa quan trọng vì nó tạo ra một mốc so sánh ban đầu. Một mô hình phức tạp chỉ thực sự có giá trị nếu cải thiện được kết quả so với baseline này.

Ưu điểm của Naive Forecast là dễ hiểu, dễ triển khai và phù hợp với các

chuỗi thời gian có tính liên tục cao trong ngắn hạn. Tuy nhiên, mô hình không khai thác được các yếu tố như thời tiết, giờ trong ngày, ngày làm việc hay chu kỳ theo tuần. Vì vậy, mô hình thường kém hiệu quả khi chuỗi có biến động mạnh hoặc chịu ảnh hưởng bởi nhiều biến ngoại sinh.

5.6 Mô hình Moving Average

Moving Average là một baseline khác được sử dụng trong đề tài. Thay vì chỉ lấy giá trị gần nhất, mô hình này dự báo bằng trung bình của một số quan sát gần nhất trong quá khứ:

$$\hat{y}_{t+1} = \frac{1}{k} \sum_{i=0}^{k-1} y_{t-i}$$

Trong đó, k là kích thước của sổ trung bình trượt. Phương pháp này giúp làm mượt chuỗi thời gian và giảm ảnh hưởng của nhiễu ngắn hạn.

Moving Average phù hợp khi chuỗi có xu hướng biến động tương đối ổn định. Tuy nhiên, đối với dữ liệu thuê xe theo giờ, nhu cầu có thể tăng hoặc giảm nhanh tại các khung giờ cao điểm. Khi đó, mô hình trung bình trượt thường phản ứng chậm với biến động mới và dễ tạo ra dự báo bị làm mượt quá mức.

5.7 Mô hình Linear Regression

Linear Regression là mô hình học máy tuyến tính được sử dụng để dự báo biến mục tiêu từ tập đặc trưng đầu vào. Mô hình giả định rằng biến mục tiêu có thể được biểu diễn bằng tổ hợp tuyến tính của các biến đầu vào:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_d x_d$$

Trong đó, $\hat{y}$ là giá trị dự báo, $x_1, x_2, \dots, x_d$ là các biến đầu vào, β_0 là hệ số chặn và $\beta_1, \beta_2, \dots, \beta_d$ là các hệ số của mô hình.

Trong bài toán này, Linear Regression sử dụng các đặc trưng đã xây dựng như biến thời gian, biến thời tiết, đặc trưng Fourier, đặc trưng trễ và đặc trưng thống kê trượt. Mô hình có ưu điểm là đơn giản, tốc độ huấn luyện nhanh và dễ giải thích. Các hệ số của mô hình có thể cho biết chiều hướng ảnh hưởng của từng biến đến nhu cầu thuê xe.

Tuy nhiên, nhu cầu thuê xe đạp thường không thay đổi theo quan hệ tuyến tính đơn giản. Nhu cầu có thể tăng mạnh vào giờ cao điểm, giảm vào ban đêm và chịu ảnh hưởng khác nhau của thời tiết theo từng khung giờ. Vì vậy, Linear Regression có thể bị hạn chế khi dữ liệu tồn tại nhiều quan hệ phi tuyến và tương tác phức tạp giữa các biến.

5.8 Mô hình Random Forest

Random Forest là mô hình học máy dạng ensemble, được xây dựng từ nhiều cây quyết định. Mỗi cây được huấn luyện trên một mẫu con của dữ liệu và một tập con các đặc trưng. Kết quả dự báo cuối cùng được tính bằng trung bình dự báo của toàn bộ các cây:

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B T_b(x)$$

Trong đó, B là số lượng cây trong rừng, $T_b(x)$ là dự báo của cây thứ b và x là vector đặc trưng đầu vào.

Random Forest phù hợp với bài toán dự báo nhu cầu thuê xe vì mô hình có khả năng mô hình hóa các quan hệ phi tuyến giữa biến đầu vào và biến mục tiêu. Chẳng hạn, ảnh hưởng của nhiệt độ đến nhu cầu thuê xe có thể khác nhau giữa buổi sáng, buổi trưa và buổi tối. Tương tự, tác động của ngày làm việc cũng có thể thay đổi theo từng khung giờ. Những tương tác như vậy thường được Random Forest khai thác tốt hơn so với mô hình tuyến tính.

Ưu điểm của Random Forest là khả năng hoạt động tốt trên dữ liệu dạng

bảng, ít yêu cầu giả định về phân phối dữ liệu và tương đối ổn định trước nhiễu. Tuy nhiên, mô hình không trực tiếp học quan hệ tuần tự theo thời gian. Do đó, hiệu quả của Random Forest phụ thuộc nhiều vào chất lượng của quá trình tạo đặc trưng, đặc biệt là các đặc trưng trễ và đặc trưng thống kê trượt.

5.9 Mô hình GRU

GRU, viết tắt của Gated Recurrent Unit, là một mô hình mạng nơ-ron hồi quy được thiết kế cho dữ liệu tuần tự. Khác với các mô hình dạng bảng, GRU xử lý dữ liệu theo thứ tự thời gian và duy trì trạng thái ẩn để lưu giữ thông tin từ các thời điểm trước đó.

GRU sử dụng các cổng điều khiển để quyết định lượng thông tin cần ghi nhớ và lượng thông tin cần cập nhật. Hai thành phần quan trọng của GRU là update gate và reset gate. Update gate kiểm soát mức độ giữ lại thông tin từ trạng thái quá khứ, trong khi reset gate quyết định mức độ sử dụng thông tin cũ khi tạo trạng thái ứng viên.

Các công thức cơ bản của GRU được biểu diễn như sau:

$$z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z)$$

$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r)$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h (r_t \odot h_{t-1}) + b_h)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

Trong đó, x_t là vector đầu vào tại thời điểm t , h_{t-1} là trạng thái ẩn ở thời điểm trước, z_t là update gate, r_t là reset gate, $\tilde{h}_t$ là trạng thái ẩn ứng viên, h_t là

trạng thái ẩn mới, σ là hàm sigmoid và $\odot$ là phép nhân từng phần tử.

Trong đề tài này, GRU nhận đầu vào là các cửa sổ thời gian có độ dài 24 giờ. Mỗi cửa sổ chứa nhiều đặc trưng tại 24 thời điểm liên tiếp, từ đó mô hình học được diễn biến nhu cầu thuê xe trong một ngày gần nhất. Cách thiết kế này đặc biệt phù hợp với dữ liệu thuê xe theo giờ vì hành vi sử dụng xe thường có tính chu kỳ rõ rệt trong ngày.

5.10 Cấu hình thực nghiệm của mô hình GRU

Cấu hình của mô hình GRU được lựa chọn nhằm cân bằng giữa khả năng học biểu diễn chuỗi thời gian và nguy cơ overfitting. Các siêu tham số chính được trình bày trong Bảng 5.2.

Bảng 5.2: Cấu hình mô hình GRU

Tham số	Giá trị
Độ dài cửa sổ đầu vào	24 giờ
Số hidden units	64
Số lớp GRU	2
Dropout	0.2
Batch size khi huấn luyện	64
Batch size khi đánh giá	128
Số epoch tối đa	40
Learning rate	0.001
Early stopping patience	7

Việc sử dụng dropout giúp giảm nguy cơ mô hình ghi nhớ quá mức dữ liệu huấn luyện. Cơ chế early stopping được áp dụng dựa trên sai số của tập validation, giúp dừng quá trình huấn luyện khi mô hình không còn cải thiện rõ rệt. Điều này làm cho quá trình huấn luyện ổn định hơn và cải thiện khả năng tổng quát hóa trên tập test.

5.11 Chuẩn hóa dữ liệu

Chuẩn hóa dữ liệu là bước cần thiết đối với các mô hình nhạy cảm với thang đo của biến đầu vào, đặc biệt là Linear Regression và GRU. Trong đề tài này, nhóm sử dụng phương pháp chuẩn hóa theo StandardScaler:

$$x' = \frac{x - \mu}{\sigma}$$

Trong đó, μ là giá trị trung bình và σ là độ lệch chuẩn. Hai tham số này chỉ được tính trên tập train, sau đó được dùng để biến đổi tập validation và tập test. Cách làm này giúp tránh rò rỉ thông tin từ dữ liệu đánh giá vào quá trình huấn luyện.

Đối với mô hình GRU, việc chuẩn hóa còn giúp quá trình tối ưu ổn định hơn, hạn chế tình trạng gradient dao động mạnh do các biến đầu vào có thang đo khác nhau. Sau khi mô hình đưa ra dự báo trên thang chuẩn hóa, giá trị dự báo được chuyển ngược về thang đo ban đầu để tính toán các chỉ số đánh giá.

5.12 Quy trình thực nghiệm

Quy trình thực nghiệm được thiết kế nhằm đảm bảo các mô hình được so sánh trong cùng điều kiện. Tất cả các mô hình đều sử dụng cùng cách chia dữ liệu theo thời gian và được đánh giá trên cùng tập test.

Bảng 5.3: Tóm tắt quy trình thực nghiệm

Giai đoạn	Nội dung thực hiện
Chuẩn bị dữ liệu	Sử dụng dữ liệu đã được tiền xử lý, tạo đặc trưng và chia thành các tập train, validation, test theo thứ tự thời gian.
Xây dựng baseline	Thiết lập Naive Forecast và Moving Average để tạo mốc so sánh ban đầu.
Huấn luyện mô hình học máy	Huấn luyện Linear Regression và Random Forest trên tập đặc trưng dạng bảng.
Huấn luyện mô hình học sâu	Chuyển dữ liệu sang dạng cửa sổ thời gian 24 giờ và huấn luyện mô hình GRU.
Đánh giá kết quả	So sánh các mô hình trên tập test bằng MAE, RMSE, MAPE và sMAPE, đồng thời phân tích đồ thị giá trị thực tế và giá trị dự báo.

Cách tổ chức thực nghiệm này giúp việc so sánh giữa các mô hình trở nên công bằng hơn. Các mô hình baseline cho biết mức dự báo tối thiểu có thể đạt được bằng các phương pháp đơn giản. Các mô hình học máy cho thấy hiệu quả của quá trình tạo đặc trưng. Mô hình GRU cho phép đánh giá lợi ích của việc học trực tiếp quan hệ tuần tự trong chuỗi thời gian.

Thông qua việc kết hợp ba nhóm mô hình, đề tài không chỉ tìm kiếm mô hình có sai số thấp nhất mà còn làm rõ vai trò của từng hướng tiếp cận trong bài toán dự báo nhu cầu thuê xe đạp theo giờ.

Chương 6

Kết quả thực nghiệm và đánh giá

6.1 Thiết lập đánh giá

Sau khi huấn luyện các mô hình, nhóm tiến hành đánh giá kết quả dự báo trên tập test. Tập test gồm 2,582 quan sát, tương ứng với phần dữ liệu cuối cùng theo thứ tự thời gian. Việc đánh giá trên tập test giúp kiểm tra khả năng dự báo của mô hình trên dữ liệu chưa được sử dụng trong quá trình huấn luyện.

Các mô hình được so sánh gồm Naive Forecast, Moving Average, Linear Regression, Random Forest và GRU. Các mô hình này đại diện cho ba nhóm tiếp cận khác nhau: mô hình baseline, mô hình học máy truyền thống và mô hình học sâu cho dữ liệu tuần tự.

Chất lượng dự báo được đánh giá thông qua bốn chỉ số: MAE, RMSE, MAPE và sMAPE. Trong đó, MAE và RMSE phản ánh sai số tuyệt đối theo cùng đơn vị với biến mục tiêu, còn MAPE và sMAPE phản ánh sai số tương đối theo phần trăm. Việc sử dụng đồng thời nhiều chỉ số giúp đánh giá mô hình toàn diện hơn, đặc biệt trong trường hợp nhu cầu thuê xe có sự chênh lệch lớn giữa giờ thấp điểm và giờ cao điểm.

6.2 Kết quả thực nghiệm

Kết quả đánh giá các mô hình trên tập test được trình bày trong Bảng 6.1.

Bảng 6.1: Kết quả đánh giá các mô hình trên tập test

Mô hình	MAE	RMSE	MAPE	sMAPE
GRU	28.39	43.98	27.69	23.94
Random Forest	34.33	57.02	23.81	20.64
Linear Regression	57.74	85.53	79.55	43.23
Naive Forecast	78.21	119.47	53.37	45.41
Moving Average	156.44	197.65	557.09	78.45

Từ Bảng 6.1, có thể thấy các mô hình học máy và học sâu đều cải thiện đáng kể so với hai mô hình baseline. GRU đạt kết quả tốt nhất theo MAE và RMSE, trong khi Random Forest đạt kết quả tốt nhất theo MAPE và sMAPE. Điều này cho thấy mỗi mô hình có ưu thế khác nhau tùy theo cách đo sai số.

6.3 Phân tích kết quả

Mô hình GRU đạt MAE bằng 28.39 và RMSE bằng 43.98, thấp nhất trong tất cả các mô hình được thử nghiệm. Kết quả này cho thấy GRU có khả năng dự báo gần với giá trị thực tế hơn khi xét theo sai số tuyệt đối. Điều này phù hợp với đặc điểm của bài toán dự báo nhu cầu thuê xe đạp theo giờ, vì nhu cầu tại một thời điểm thường phụ thuộc mạnh vào các giá trị trong quá khứ gần, chu kỳ trong ngày và xu hướng thay đổi theo thời gian. Với cơ chế cổng nhớ, GRU có khả năng học các phụ thuộc tuần tự trong chuỗi thời gian tốt hơn so với các mô hình không xử lý dữ liệu theo dạng chuỗi.

Random Forest cũng cho kết quả tốt, với MAPE bằng 23.81 và sMAPE bằng 20.64, thấp nhất trong các mô hình. Mô hình này có khả năng khai thác hiệu quả các đặc trưng dạng bảng như biến thời gian, biến thời tiết, Fourier features, lag features và rolling features. Ngoài ra, Random Forest có thể mô hình hóa các

quan hệ phi tuyến giữa các biến đầu vào và biến mục tiêu, chẳng hạn ảnh hưởng khác nhau của nhiệt độ, giờ trong ngày và ngày làm việc đến nhu cầu thuê xe. Tuy nhiên, Random Forest không trực tiếp học quan hệ tuần tự theo thời gian như GRU mà phụ thuộc nhiều hơn vào chất lượng của quá trình tạo đặc trưng.

Linear Regression có kết quả tốt hơn hai baseline theo MAE và RMSE, cho thấy các đặc trưng được xây dựng có chứa thông tin hữu ích cho bài toán dự báo. Tuy nhiên, mô hình này kém hơn Random Forest và GRU do giả định quan hệ tuyến tính giữa biến đầu vào và biến mục tiêu. Trong thực tế, nhu cầu thuê xe thường thay đổi theo các quy luật phi tuyến, chẳng hạn tăng mạnh vào giờ cao điểm, giảm vào ban đêm và chịu ảnh hưởng khác nhau của điều kiện thời tiết theo từng khung giờ.

Hai mô hình baseline gồm Naive Forecast và Moving Average có kết quả kém hơn rõ rệt. Naive Forecast chỉ sử dụng giá trị gần nhất trong quá khứ để dự báo nên không khai thác được các biến ngoại sinh như nhiệt độ, độ ẩm, ngày trong tuần hay giờ trong ngày. Moving Average có xu hướng làm mượt chuỗi thời gian, vì vậy thường phản ứng chậm với các biến động đột ngột, đặc biệt tại các khung giờ cao điểm. Đây là nguyên nhân khiến Moving Average có sai số lớn nhất trong các mô hình được đánh giá.


Một điểm cần lưu ý là MAPE có thể bị ảnh hưởng mạnh khi giá trị thực tế của biến y nhỏ, ví dụ vào ban đêm hoặc các khung giờ có nhu cầu thấp. Khi mẫu số nhỏ, chỉ một sai lệch tuyệt đối không quá lớn cũng có thể tạo ra sai số phần trăm cao. Vì vậy, trong bài toán này, nhóm không chỉ dựa vào MAPE mà xem xét đồng thời MAE, RMSE, sMAPE và đồ thị so sánh giữa giá trị thực tế và giá trị dự báo.

Tổng hợp các kết quả, GRU được xem là mô hình phù hợp nhất trong phạm vi thực nghiệm của đề tài do đạt sai số tuyệt đối thấp nhất và có khả năng học quan hệ theo thời gian. Random Forest là mô hình học máy truyền thống có hiệu quả tốt, dễ huấn luyện và dễ giải thích hơn, phù hợp để làm mô hình so

sánh mạnh. Các mô hình baseline tuy có độ chính xác thấp hơn nhưng vẫn cần thiết để làm mốc đánh giá, giúp chứng minh rằng việc bổ sung đặc trưng và sử dụng mô hình nâng cao đã cải thiện chất lượng dự báo.

6.4 Trực quan hóa kết quả dự báo

Bên cạnh các chỉ số định lượng, nhóm sử dụng đồ thị so sánh giữa giá trị thực tế và giá trị dự báo để quan sát trực quan khả năng bám sát xu hướng của các mô hình trên tập test.




Hình 6.1: So sánh giá trị thực tế và giá trị dự báo trên tập test

Hình 6.1 cho thấy Random Forest và GRU bám sát xu hướng thực tế tốt hơn so với các baseline. Naive Forecast có thể theo sát xu hướng trong một số đoạn ngắn nhưng dễ bị lệch khi nhu cầu thay đổi nhanh. Moving Average làm mượt chuỗi quá mạnh nên thường phản ứng chậm với các đỉnh hoặc đáy của nhu cầu thuê xe.

Kết quả trực quan này phù hợp với bảng chỉ số định lượng. Các mô hình khai thác được thông tin từ nhiều biến đầu vào và thông tin quá khứ cho kết quả ổn định hơn so với các phương pháp chỉ dựa trên giá trị trung bình hoặc giá trị gần nhất.

6.5 Quá trình huấn luyện GRU

Đối với mô hình GRU, nhóm theo dõi train loss và validation loss trong quá trình huấn luyện để kiểm tra khả năng học của mô hình. Việc theo dõi đồng thời hai đường loss giúp nhận biết mô hình có đang học được cấu trúc dữ liệu hay có dấu hiệu overfitting hay không.



Hình 6.2: Đường cong huấn luyện của mô hình GRU

Hình 6.2 cho thấy loss trên tập train và validation giảm trong quá trình huấn luyện. Điều này cho thấy mô hình học được cấu trúc dữ liệu thay vì chỉ dự báo ngẫu nhiên. Việc sử dụng validation loss và early stopping giúp hạn chế overfitting, đồng thời lựa chọn được trạng thái mô hình có khả năng tổng quát hóa tốt hơn trên dữ liệu chưa thấy.

6.6 So sánh tổng quát các mô hình

Bảng 6.2 tóm tắt điểm mạnh và hạn chế của từng mô hình trong bối cảnh bài toán dự báo nhu cầu thuê xe đạp theo giờ.

Bảng 6.2: So sánh tổng quát các mô hình

Mô hình	Điểm mạnh	Hạn chế
Naive Forecast	Đơn giản, không cần huấn luyện, phù hợp làm baseline ban đầu.	Không khai thác được mùa vụ, thời tiết và các biến ngoại sinh.
Moving Average	Dễ hiểu, có khả năng làm mượt dao động ngắn hạn.	Phản ứng chậm với biến động nhanh, dễ bỏ lỡ các đỉnh và đáy của chuỗi.
Linear Regression	Dễ giải thích, huấn luyện nhanh, cho thấy hiệu quả ban đầu của feature engineering.	Giả định quan hệ tuyến tính, khó học các quan hệ phi tuyến và tương tác phức tạp.
Random Forest	Học được quan hệ phi tuyến, tận dụng tốt các đặc trưng đã xây dựng, đạt MAPE và sMAPE tốt nhất.	Không trực tiếp học dữ liệu dưới dạng chuỗi tuần tự, phụ thuộc nhiều vào chất lượng đặc trưng.
GRU	Học được phụ thuộc theo thời gian, đạt MAE và RMSE tốt nhất.	Huấn luyện lâu hơn, khó giải thích hơn so với các mô hình truyền thống.

Từ bảng so sánh, có thể thấy không có mô hình nào vượt trội tuyệt đối trên mọi khía cạnh. Nếu ưu tiên sai số tuyệt đối thấp và khả năng học quan hệ thời gian, GRU là lựa chọn phù hợp nhất. Nếu ưu tiên mô hình dễ huấn luyện, khai thác tốt đặc trưng dạng bảng và có sai số tương đối thấp, Random Forest là lựa chọn đáng chú ý. Các mô hình baseline vẫn đóng vai trò quan trọng vì cung cấp mốc so sánh để đánh giá mức cải thiện của các mô hình phức tạp hơn.

Chương 7

Kết luận và hướng phát triển

7.1 Kết luận chung

Trong đề án này, nhóm đã nghiên cứu và xây dựng một quy trình dự báo nhu cầu thuê xe đạp theo giờ dựa trên dữ liệu chuỗi thời gian nhiều chiều. Bài toán được xác định với đầu vào là nhiều biến theo thời gian, bao gồm thông tin lịch, thời tiết, đặc trưng chu kỳ và thông tin nhu cầu thuê xe trong quá khứ; đầu ra là biến mục tiêu một chiều `cnt`, biểu thị tổng số lượt thuê xe trong giờ cần dự báo.

Nhóm sử dụng bộ dữ liệu *UCI Bike Sharing Dataset*, tập trung vào dữ liệu theo giờ trong giai đoạn từ năm 2011 đến năm 2012. Đây là bộ dữ liệu phù hợp với yêu cầu của đề án vì có tần suất theo giờ, có nhiều biến đầu vào và có biến mục tiêu rõ ràng. Trên cơ sở dữ liệu này, nhóm đã thực hiện đầy đủ các bước từ phân tích khám phá dữ liệu, tiền xử lý, tạo đặc trưng, chia dữ liệu theo thứ tự thời gian, xây dựng mô hình và đánh giá kết quả.

Kết quả thực nghiệm cho thấy các mô hình học máy và học sâu cải thiện đáng kể so với các mô hình baseline đơn giản. Trong đó, GRU đạt kết quả tốt nhất theo MAE và RMSE, cho thấy khả năng dự báo tốt theo sai số tuyệt đối. Random Forest đạt kết quả tốt nhất theo MAPE và sMAPE, cho thấy hiệu quả ổn định khi xét sai số tương đối. Điều này khẳng định rằng việc khai thác thông

tin đa biến, thông tin mùa vụ và phụ thuộc theo thời gian có vai trò quan trọng trong bài toán dự báo nhu cầu thuê xe.

7.2 Kết quả đạt được

Thông qua quá trình thực hiện đề án, nhóm đã đạt được một số kết quả chính sau:

- Xây dựng được bài toán dự báo chuỗi thời gian nhiều chiều với đầu vào là nhiều biến theo thời gian và đầu ra là một biến mục tiêu.
- Tìm hiểu và tóm tắt ba bài báo liên quan đến dự báo chuỗi thời gian nhiều chiều gồm iTransformer, TimeMixer và xLSTM-Mixer.
- Phân tích bộ dữ liệu UCI Bike Sharing Dataset và xác định được các đặc điểm quan trọng của biến mục tiêu `cnt`.
- Thực hiện tiền xử lý dữ liệu, bao gồm kiểm tra missing values, kiểm tra tần suất lấy mẫu, xử lý ngoại lai và loại bỏ biến gây rò rỉ dữ liệu.
- Xây dựng hệ đặc trưng gồm đặc trưng thời gian, Fourier features, lag features và rolling features.
- Chia dữ liệu thành train, validation và test theo đúng thứ tự thời gian để tránh rò rỉ thông tin tương lai.
- Xây dựng và so sánh năm mô hình dự báo: Naive Forecast, Moving Average, Linear Regression, Random Forest và GRU.
- Đánh giá mô hình bằng MAE, RMSE, MAPE, sMAPE và trực quan hóa kết quả dự báo bằng đồ thị so sánh giá trị thực tế với giá trị dự báo.

Những kết quả này cho thấy nhóm đã hoàn thành các yêu cầu cốt lõi của bài toán chuỗi thời gian nhiều chiều và xây dựng được một quy trình thực nghiệm có tính hệ thống.

7.3 Đóng góp của đề án

Đóng góp chính của đề án nằm ở việc xây dựng một quy trình hoàn chỉnh cho bài toán dự báo nhu cầu thuê xe đạp theo giờ. Quy trình này bắt đầu từ việc hiểu bài toán, phân tích dữ liệu, xử lý các vấn đề đặc thù của chuỗi thời gian, xây dựng đặc trưng và đánh giá nhiều mô hình dự báo khác nhau.

Về mặt dữ liệu, nhóm đã chỉ ra rằng nhu cầu thuê xe có tính mùa vụ rõ rệt theo giờ trong ngày, ngày trong tuần và mùa trong năm. Về mặt đặc trưng, nhóm đã kết hợp các biến thời gian, biến thời tiết, đặc trưng chu kỳ, đặc trưng trễ và đặc trưng thống kê trượt để biểu diễn tốt hơn thông tin đầu vào. Về mặt mô hình, nhóm đã so sánh các phương pháp từ đơn giản đến phức tạp, qua đó làm rõ vai trò của baseline, mô hình học máy truyền thống và mô hình học sâu trong dự báo chuỗi thời gian.

Kết quả thực nghiệm cho thấy việc bổ sung đặc trưng và sử dụng mô hình có khả năng học quan hệ phi tuyến hoặc quan hệ tuần tự giúp cải thiện đáng kể chất lượng dự báo so với các phương pháp baseline.

7.4 Hạn chế của đề án

Mặc dù đã hoàn thành các mục tiêu chính, đề án vẫn còn một số hạn chế.

Thứ nhất, nhóm chưa triển khai trực tiếp các kiến trúc hiện đại như iTransformer, TimeMixer hoặc xLSTM-Mixer. Các mô hình này mới được sử dụng làm cơ sở tham khảo về mặt ý tưởng. Phần thực nghiệm tập trung vào các mô hình phù hợp hơn với phạm vi triển khai của nhóm như Random Forest và GRU.

Thứ hai, mô hình GRU mới được huấn luyện với cấu hình tương đối cơ bản, chưa thực hiện tối ưu sâu các siêu tham số. Việc lựa chọn số hidden units, số layer, learning rate, batch size hoặc độ dài cửa sổ đầu vào có thể ảnh hưởng đáng

kể đến chất lượng dự báo.

Thứ ba, dữ liệu sử dụng trong đồ án không có thông tin vị trí từng trạm xe, do đó nhóm chưa thể xây dựng mô hình dự báo theo không gian - thời gian. Bài toán hiện tại chỉ tập trung vào tổng nhu cầu thuê xe theo giờ.

Thứ tư, dữ liệu có một số timestamp bị thiếu. Trong phạm vi đồ án, nhóm giữ nguyên các quan sát có sẵn và không thực hiện nội suy để tái lập timeline hourly hoàn chỉnh. Cách xử lý này đơn giản và hạn chế giả định bổ sung, nhưng có thể chưa khai thác hết cấu trúc thời gian đều của dữ liệu.

Cuối cùng, đồ án mới tập trung vào dự báo một bước trước, tức là dự báo nhu cầu ở giờ tiếp theo. Trong thực tế, các bài toán vận hành thường cần dự báo nhiều bước trong tương lai để hỗ trợ lập kế hoạch tốt hơn.

7.5 Hướng phát triển

Trong tương lai, đề tài có thể được mở rộng theo một số hướng.

Trước hết, có thể triển khai trực tiếp các mô hình hiện đại như iTransformer, TimeMixer hoặc xLSTM-Mixer để so sánh với GRU và Random Forest. Việc này giúp đánh giá rõ hơn hiệu quả của các kiến trúc mới trong bài toán dự báo nhu cầu thuê xe theo giờ.

Tiếp theo, có thể tối ưu sâu hơn các siêu tham số của mô hình. Đối với GRU, các tham số như số hidden units, số layer, dropout, learning rate, batch size và độ dài của sổ đầu vào có thể được điều chỉnh bằng Grid Search, Random Search hoặc Bayesian Optimization. Đối với Random Forest, có thể tối ưu số lượng cây, độ sâu tối đa và số đặc trưng được chọn tại mỗi lần chia.

Một hướng phát triển khác là mở rộng bài toán sang dự báo nhiều bước trong tương lai, chẳng hạn dự báo 6 giờ, 12 giờ hoặc 24 giờ tiếp theo. Hướng này có ý nghĩa thực tiễn cao hơn vì giúp hệ thống chia sẻ xe đạp lập kế hoạch điều phối phương tiện trước nhiều giờ.

Ngoài ra, có thể bổ sung thêm các nguồn dữ liệu bên ngoài như dữ liệu thời tiết chi tiết hơn, dữ liệu sự kiện đặc biệt, ngày lễ theo khu vực hoặc dữ liệu giao thông. Các nguồn dữ liệu này có thể giúp mô hình giải thích tốt hơn những biến động bất thường trong nhu cầu thuê xe.

Nếu có dữ liệu theo từng trạm, bài toán cũng có thể được mở rộng thành dự báo không gian - thời gian. Khi đó, mô hình không chỉ cần học quan hệ theo thời gian mà còn cần học quan hệ giữa các vị trí trạm xe khác nhau.

7.6 Kết luận cuối cùng

Tổng kết lại, đề án đã đáp ứng đúng yêu cầu về bài toán chuỗi thời gian nhiều chiều: đầu vào là nhiều biến theo thời gian và đầu ra là một biến mục tiêu một chiều. Nhóm đã xây dựng được một quy trình tương đối hoàn chỉnh từ nghiên cứu bài báo, phân tích dữ liệu, tiền xử lý, tạo đặc trưng, huấn luyện mô hình đến đánh giá kết quả.

Kết quả thực nghiệm cho thấy các mô hình học máy và học sâu, đặc biệt là Random Forest và GRU, cho kết quả tốt hơn rõ rệt so với các baseline đơn giản. Điều này khẳng định rằng feature engineering, lựa chọn mô hình phù hợp và nguyên tắc tránh rò rỉ dữ liệu đóng vai trò quan trọng trong bài toán dự báo chuỗi thời gian.

Qua đề án, nhóm hiểu rõ hơn cách tiếp cận một bài toán dự báo thực tế, từ khâu xác định bài toán đến đánh giá kết quả mô hình. Đây là nền tảng quan trọng để tiếp tục nghiên cứu các mô hình chuỗi thời gian nâng cao trong tương lai.

Tài liệu tham khảo

- [1] UCI Machine Learning Repository. *Bike Sharing Dataset*. <https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset>
- [2] Liu, Y., Hu, T., Zhang, H., Wu, H., Wang, S., Ma, L., and Long, M. *iTransformer: Inverted Transformers Are Effective for Time Series Forecasting*.
- [3] Wang, S., Wu, H., Shi, X., Hu, T., Luo, H., Ma, L., Zhang, J. Y., and Zhou, J. *TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting*.
- [4] Kraus, M., Divo, F., Dhimi, D. S., and Kersting, K. *xLSTM-Mixer: Multivariate Time Series Forecasting by Mixing via Scalar Memories*. <https://arxiv.org/abs/2410.16928>
- [5] Scikit-learn Documentation. *Linear Regression and Random Forest Regressor*. <https://scikit-learn.org/>
- [6] PyTorch Documentation. *GRU*. <https://pytorch.org/docs/stable/generated/torch.nn.GRU.html>